基于文本挖掘与异常检测的政府采购异常低价中标风险识别研究

——来自中国政府采购网中标公告数据的证据

摘要

异常低价中标是政府采购领域较为典型且长期存在的监管难题。其表层特征表现为成交价格明显低于预算或同类项目常规水平，深层机理则可能关联履约质量下降、供应商策略性报价、采购方式约束、地区财政压力以及交易关系固化等多重因素。随着政府采购公告、合同与信用信息持续在线化，单纯依赖人工经验和统一价格阈值的审查方式，已难以满足多类别、多主体、多地区风险识别的治理需求。

本文以中国政府采购网公告数据、2025 年第一季度合同扩展样本和 2024 年省级宏观指标为基础，经过清洗、标准化和跨源融合，形成 7,885 条项目级样本，其中价格有效样本 7,720 条、服务类主样本 5,588 条、2025Q1 扩展样本 4,500 条。在指标构造方面，研究从政策参考阈值、类别内分位数、箱线图 IQR 和稳健 Z 分数四个维度生成异常低价初始标签。

在此基础上，本文进一步采用 Isolation Forest、LOF 和 One-Class SVM 构建集成异常检测模型，并将规则风险得分纳入综合风险分数。模型在服务类主样本中识别出高风险项目 559 个，占比 10.00%。随后，研究利用 Logistic 回归、Random Forest、XGBoost 和 SHAP 开展风险因素解释。结果表明，XGBoost 能

够较好复现风险标签在特征空间中的分布结构，价格比例、节约率、供应商风险画像、财政压力和人均 GDP 等变量对模型输出具有较强解释力。进一步的 QCA 和关系网络分析显示，异常低价风险具有多条件并发和主体关系嵌入特征。

研究表明，异常低价风险并非单一价格偏离问题，而是采购类别、供应商行为、地区环境和交易网络共同作用的结果。基于实证发现，本文建议建立自动预警、类别阈值、供应商画像、重点地区与采购方式监管以及履约跟踪相衔接的闭环治理机制。

关键词：政府采购；异常低价中标；风险识别；异常检测；监管治理

目录

一、引言
二、数据来源与预处理
三、政府采购异常低价风险指标构建
四、文本特征工程与项目画像构建
五、异常低价中标风险识别模型
六、风险因素解释与风险线索组合分析
七、采购关系网络与风险聚集分析
八、稳健性检验与扩展分析
九、结论与政策建议
参考文献

一、引言

（一）研究背景与问题提出

政府采购是财政资金配置、公共服务供给和国家治理能力现代化的重要制度安排。伴随采购规模扩大和电子化平台建设推进，公告文本、合同信息、供应商资料、价格数据与履约线索不断沉淀为可计算、可追溯的数据资源。与此同时，异常低价中标现象在实践中仍较为突出：部分项目以显著低于预算或同类项目市场水平的价格成交，后续可能通过降低服务质量、追加变更、压缩人

员配置或履约替代等方式转移成本。与一般意义上的节约财政资金不同，异常低价更强调价格偏离与履约风险之间的联动关系，因而具有更强的治理复杂性。

从监管实践观察，异常低价中标通常伴随三类后续风险：其一，履约阶段通过降低服务标准、减少资源投入或申请合同变更弥补报价缺口；其二，形成“低价中标—履约困难—追加采购”的循环，导致财政资金综合支出上升；其三，个别供应商利用低价策略排挤竞争者，并在后续续约或关联采购中提高报价，削弱市场竞争。由此可见，异常低价识别不能停留于投标价格本身，还应关注其背后的履约能力、竞争结构和监管可验证性。

传统监管主要依赖固定阈值、专家经验和人工复核。这一方式在小规模、低频次采购场景中具有一定可行性，但面对跨地区、多类别、高频次的政府采购数据时，容易暴露三方面不足：第一，统一阈值难以反映不同服务类别的成本结构差异，可能混淆合理让利与异常低价；第二，公告文本和供应商交易行为未被充分利用，难以解释风险形成机制；第三，监管对象多聚焦单个项目，较少识别供应商—采购人关系网络中的重复交易和风险聚集。

基于上述问题，本文将异常低价识别界定为多源数据支撑下的风险治理问题，而非单纯的价格审查问题。研究以政府采购项目级数据为对象，旨在构建可解释、可复核并可服务监管决策的异常低价风险识别框架。需要强调的是，模型输出并不等同于违法认定，而是用于形成监管预警线索，为后续人工复核、履约跟踪和分类处置提供依据。该定位有助于在提高识别效率的同时，保持行政监管必要的审慎性和程序正当性。

（二）文献综述

国外关于异常低价识别的研究大体形成三类路径。第一类聚焦价格统计检验和计量识别。Jeong、Lee 和 Kim 通过判别分析识别采购市场中的异常低价投标[8]；Conti、De Giovanni 和 Naldi 提出 rank-and-compare 算法检测采购拍卖中的异常低价报价[9]；Hinojosa、Muñoz 和 Oviedo 则围绕 PPP 项目提出统计检验方案[10]。相关研究共同表明，异常低价识别需要兼顾检测概率、误报风险和报价离散程度。

第二类关注公共采购腐败风险和红旗指标。Fazekas、Tóth 和 King 基于公共采购大数据构建客观腐败风险指数，强调限制竞争、重复中标和程序异常等红

旗变量[13]；Decarolis 和 Giorgiantonio 进一步利用意大利招标公告构造腐败红旗指标[14]。此类研究提示，价格异常往往需要与程序、主体和文本线索结合解释，才能形成更具监管意义的风险判断。

第三类强调机器学习、文本挖掘和网络分析方法。Rabuzin 和 Modrušan 使用机器学习与文本挖掘预测公共采购腐败指数[11]；Lima 等构建多面向采购文本学习数据集，为公共采购文本建模提供数据基础[12]；Lyra、Pinheiro 和 Bação 综述网络分析在公共采购欺诈检测中的应用，指出主体连接结构能够揭示重复交易、中心节点和潜在合谋关系[16]。这些成果表明，异常低价风险具有多维数据特征，单一价格变量难以完整刻画其生成机制。

国内研究更多围绕政府采购文本挖掘、异常低价法律规制和招投标数据治理展开。王宏等将 K 近邻算法用于政府采购数据挖掘[1]，韩利利研究中标公告文本挖掘在政府采购中的应用[2]；苏莹莹和张怀营分别从法律规制与指导性案例角度讨论异常低价投标行为[3-4]；魏俊奎等以电力供应商投标评估为例说明大数据分析在供应商预测评价中的应用[5]。总体而言，国内研究已认识到异常低价问题的复杂性，但在跨源数据融合、模型解释和监管应用转化方面仍有进一步拓展空间。

具体来看，既有研究仍存在三方面不足：第一，部分价格规则采用全局阈值或简单分位数，未充分区分不同服务类别的成本差异；第二，文本挖掘和主题模型在政府采购场景中的应用仍处于拓展阶段，对采购需求结构、限制性条款和地区因素的挖掘不够深入；第三，异常检测、监督解释和关系网络分析多被分散使用，较少形成从识别、解释到监管行动的完整闭环。对于监管部门而言，真正有价值的模型不仅应给出风险排序，还应说明风险来自何种价格偏离、主体行为和制度环境，并能够转化为可执行的复核清单。

（三）研究内容、技术路线与创新点

本文构建“数据治理—风险标签—异常检测—风险解释—监管决策”的五阶段研究框架。第一阶段对原始公告和合同数据进行清洗、字段统一、服务类型映射、供应商名称标准化以及省级宏观指标融合；第二阶段从固定阈值、类别分位数、IQR 和稳健 Z 分数构造异常低价规则标签；第三阶段采用 Isolation Forest、LOF 和 One-Class SVM 识别多维异常项目；第四阶段借助 XGBoost、

SHAP 和 QCA 解释风险因素及其组合路径；第五阶段结合关系网络和稳健性检验提出可操作的监管建议。该框架兼顾统计识别、业务解释和监管落地，力求避免模型结果停留在技术层面。

本文的可能创新主要体现在三个方面：一是将异常低价识别由单一固定阈值扩展为类别内相对价格偏离和多规则投票，提高规则标签的稳健性；二是将公告文本主题、供应商画像和地区宏观变量纳入模型特征，避免仅以价格判断风险；三是将模型结果嵌入主体关系网络和监管建议，形成从风险识别到证据解释、再到分类监管的分析链条。

图1 研究技术路线图

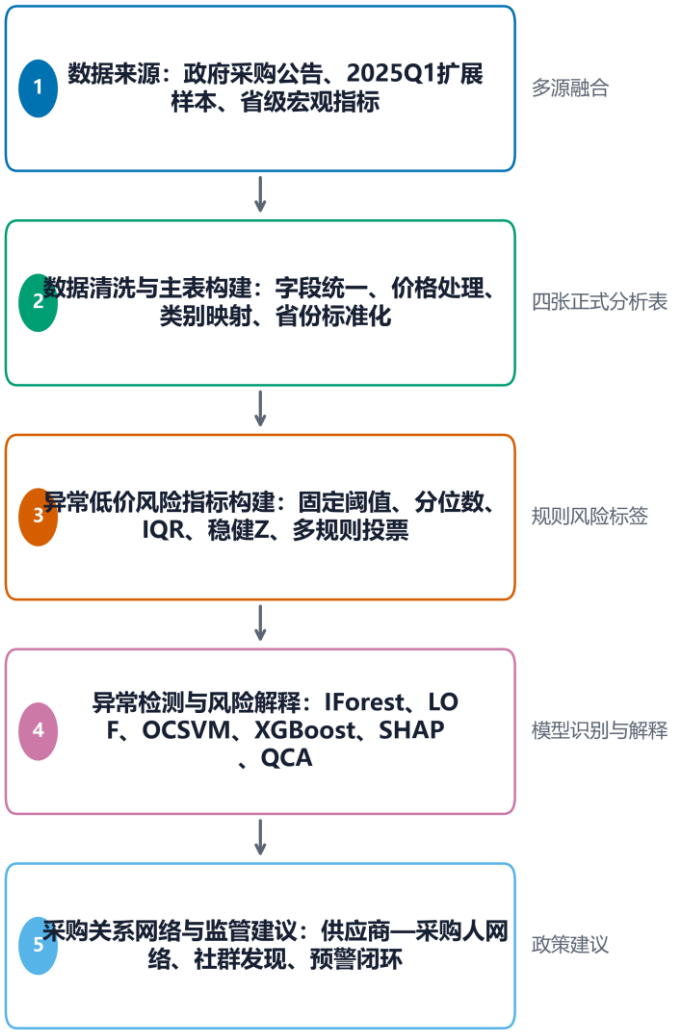


图 1 研究技术路线图

二、数据来源与预处理

（一）数据来源

本文使用两类政府采购项目数据：一类来源于中国政府采购网公告与中标信息，另一类为 2025 年第一季度合同扩展样本。宏观控制变量来自 2024 年省级 GDP、人口、人均 GDP、财政收入、财政支出、财政压力、平均工资、第三产业占比和城镇化率等指标。2025 年部分省级指标主要用于补充描述，正式建模中的地区控制变量以 2024 年完整省级数据为准。

表 1 数据来源说明表

数据集	样本量	字段数	正式用途
全样本表	7885	55	总体描述、数据结构、采购大类分布
价格有效样本表	7720	55	异常低价规则标签构造
服务类主样本表	5588	55	主模型、风险解释、SHAP、QCA、关系网络
2025Q1 扩展样本表	4500	55	稳健性检验与扩展分析
主表_v2	7885	55	总备份主表与清洗记录

（二）字段结构与清洗流程

数据清洗遵循项目级分析口径。首先统一公告标题、项目名称、采购人、供应商、预算金额、中标金额、采购方式、服务类别、项目省份和公告正文等字段；其次删除预算金额或中标金额缺失、为零或极端解析异常的记录；再次将深圳、青岛、厦门等城市型省份字段映射到所属省份，并在项目省份缺失但项目城市可识别时通过城市反推省份；最后合并省级宏观指标，形成主表及四张建模表。

数据清洗遵循项目级分析口径。首先统一公告标题、项目名称、采购人、供应商、预算金额、中标金额、采购方式、服务类别、项目省份和公告正文等字段；其次剔除预算金额或中标金额缺失、为零以及解析明显异常的记录；再次将深圳、青岛、厦门等城市型字段映射至所属省份，并在项目省份缺失但城市可识别时反推省份；最后合并省级宏观指标，形成可用于建模的项目层数据集。

在供应商名称标准化方面，本文针对同一供应商因简称、括号注释、空格差异或行政区划前缀不同而形成的多条记录，设计了基于关键词规则和模糊相似度的归并流程：先剔除常见无实质含义后缀，再对剩余核心名称计算编辑距离，对名称高度相似且中标地区重合的记录进行合并。该处理有助于减少供应商画像中的虚假多主体问题。

清洗后的字段可概括为公告文本、价格、采购主体、类型、地区、宏观环境和规则风险七类，分别服务于文本特征提取、价格规则构造、供应商画像、分组比较、地区差异分析和异常标签生成。

图2 数据清洗流程图



图 2 数据清洗流程图

（三）样本划分与描述性统计

清洗后主表共包含 7,885 条记录。为匹配论文分析逻辑，本文从主表派生四个正式分析版本：全样本表用于描述性统计，价格有效样本表用于异常低价规则构造，服务类主样本表用于主模型、解释分析和关系网络，2025Q1 扩展样本表用于稳健性检验。

表 2 清洗后样本划分表

输出数据	样本量	价格有效比例	规则高风险比例	用途
全样本表	7885	97.91%	8.61%	总体描述
价格有效样本表	7720	100.00%	8.41%	规则风险识别
服务类主样本表	5588	100.00%	9.40%	主模型分析
2025Q1 扩展样本表	4500	99.38%	6.47%	稳健性检验

表 3 采购大类分布表

采购大类	项目数量	占比
服务类	5743	72.83%

采购大类	项目数量	占比
货物类	1747	22.16%
工程类	321	4.07%
其他	74	0.94%

从采购大类看，服务类样本占比最高，因而构成本文主模型分析重点；货物类、工程类和其他项目主要用于全样本描述和扩展样本稳健性比较。服务类别方面，物业管理、办公设备与耗材、信息化服务、运维维护、保洁服务和安保服务构成主要类别，反映样本同时覆盖后勤服务、信息技术服务和通用货物采购等典型场景。

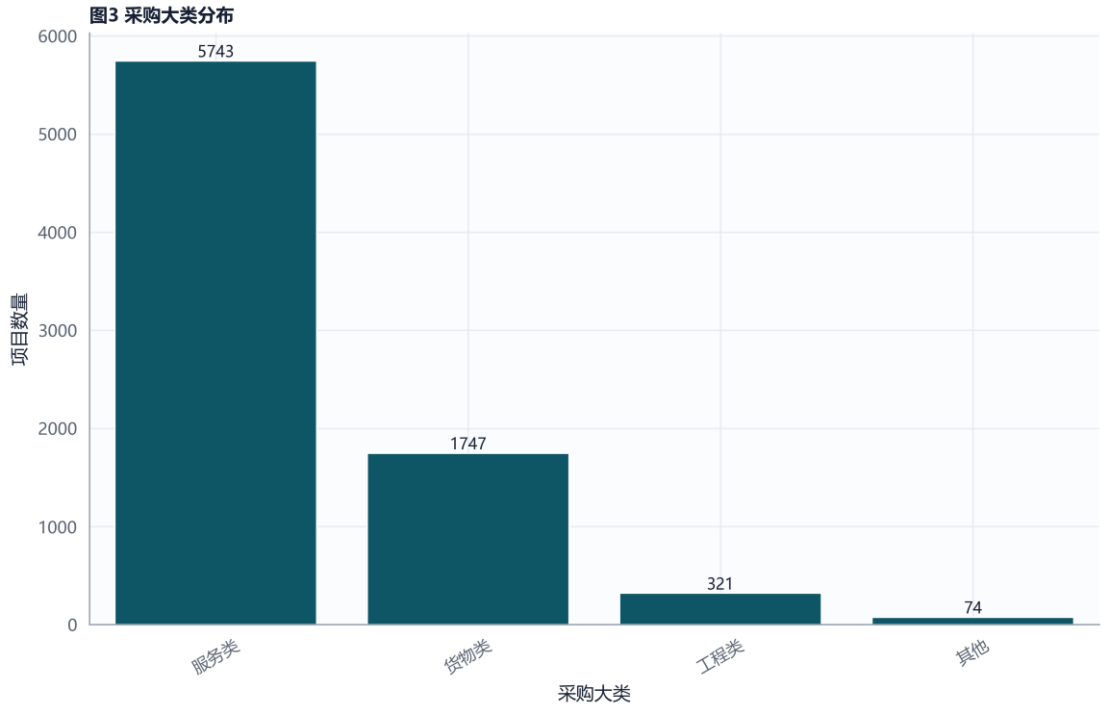


图 3 采购大类分布图

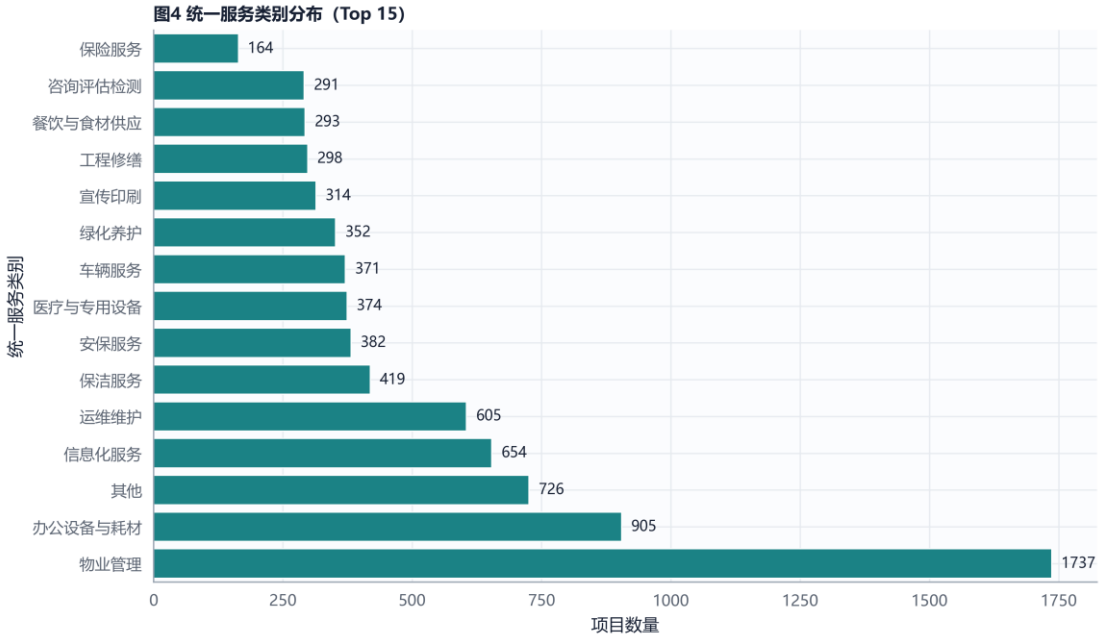


图 4 统一服务类别分布图

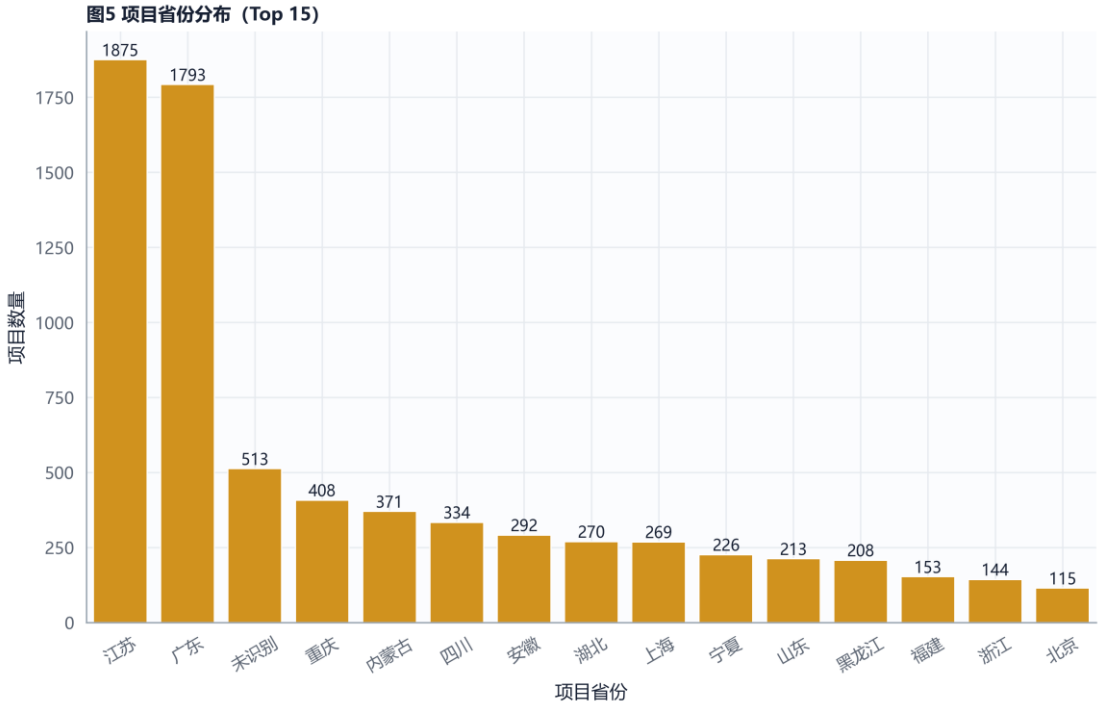


图 5 项目省份分布图

三、政府采购异常低价风险指标构建

（一）基础价格指标

异常低价首先体现为成交价格相对预算或同类项目价格的显著偏离。本文以预算金额和中标金额为基础，构造中标/预算比例、节约率、对数预算金额和对数中标金额。为降低金额解析异常对规则识别的干扰，仅将预算金额大于

100 元、中标金额大于 100 元且 0<中标/预算比例≤1 的记录纳入价格有效样本。其中，M_i 表示第 i 个项目的中标金额，B_i 表示预算金额，R_i 表示中标/预算比例，G_i 表示节约率。

$$R_i = \frac{M_i}{B_i}, \quad G_i = 1 - R_i \qquad \text{公式(1)}$$

清洗结果显示，价格有效样本为 7,720 条。主表中仍保留异常价格标记，以便开展数据说明和稳健性讨论。其中，中标/预算比例小于 0.01 的记录 60 条，比例等于 0 的记录 17 条，比例大于 1 的记录 93 条，中标金额不超过 100 元的记录 74 条，预算金额不超过 100 元的记录 48 条。

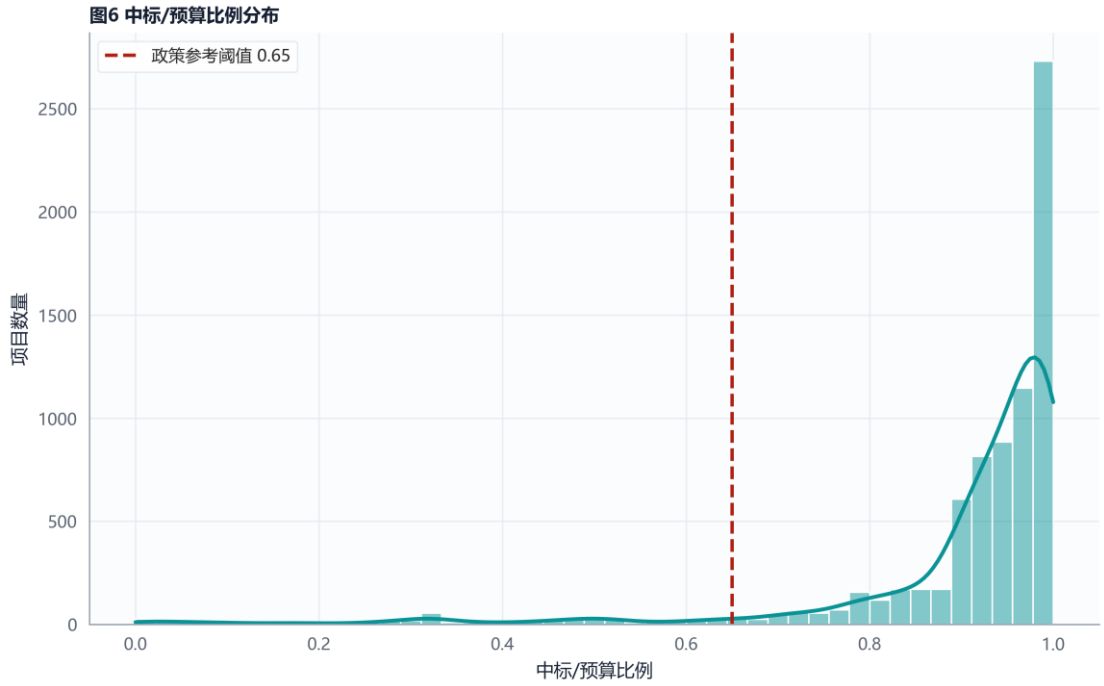


图 6 中标/预算比例分布图

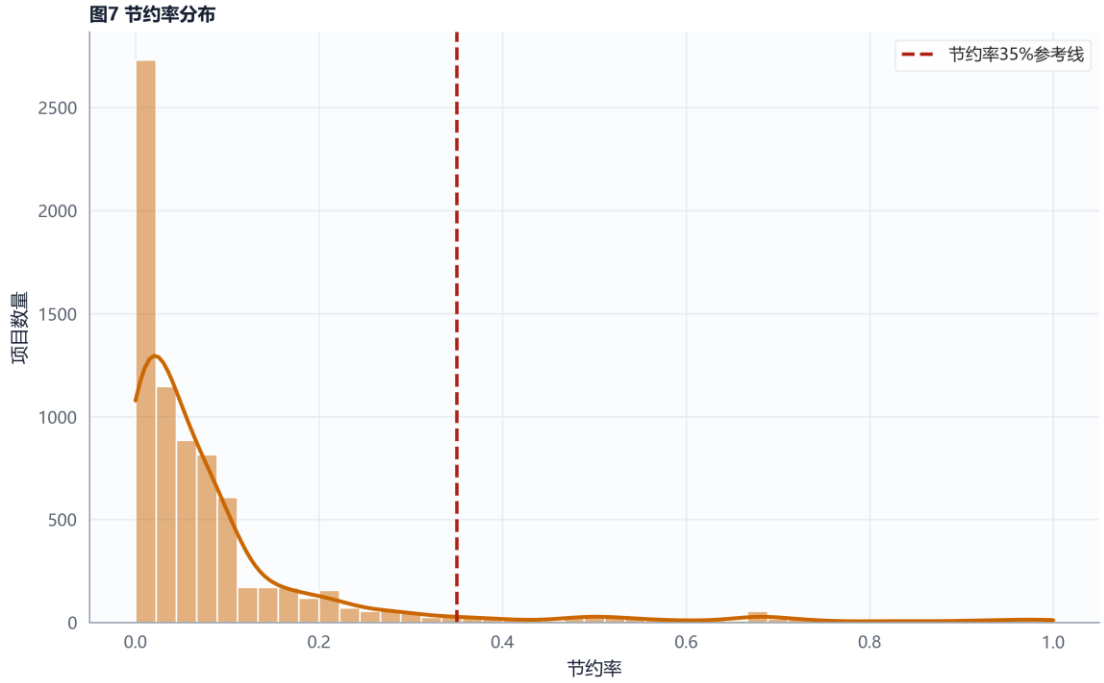


图 7 节约率分布图

（二）多规则异常低价标签

单一价格阈值容易忽略采购类别差异。借鉴异常低价统计检验和红旗指标研究[8-14]，本文从固定阈值、类别分位数、箱线图异常值和稳健 Z 分数四个角度构造规则标签。固定阈值用于捕捉明显低于预算的项目，类别分位数用于识别同类项目中的相对低价，IQR 适合检测箱线图下界外的离群值，稳健 Z 分数则通过中位数和 MAD 降低极端观测值影响。

具体规则如下。其中，c_i 表示第 i 个项目所属的统一服务类别，g 表示某一服务类别，α 取 0.05 或 0.10，T 表示相应规则阈值；当 R_i 低于阈值或 Z_i 小于设定界限时，项目触发对应异常规则：

$$T_{g,\alpha} = Q_{\alpha}(R_i \mid c_i = g), \quad \alpha \in \{0.05, 0.10\} \qquad \text{公式(2)}$$

$$T_{g,IQR} = Q_{1,g} - 1.5\left(Q_{3,g} - Q_{1,g}\right) \qquad \text{公式(3)}$$

$$Z_i = \frac{R_i - \mathrm{Median}_g}{1.4826 \times \mathrm{MAD}_g} \qquad \text{公式(4)}$$

表 4 规则识别结果对比表

规则类型	识别异常项目数量	识别比例	口径说明
政策阈值<0.65	457	5.92%	中标/预算比例低于 0.65
同类别 10%分位	752	9.74%	低于同服务类别第 10 百分位

规则类型	识别异常项目数量	识别比例	口径说明
同类别 5%分位	368	4.77%	低于同服务类别第 5 百分位
IQR 离群	667	8.64%	低于同服务类别箱线图下界
稳健 Z 分数	840	10.88%	稳健 Z 分数显著为负

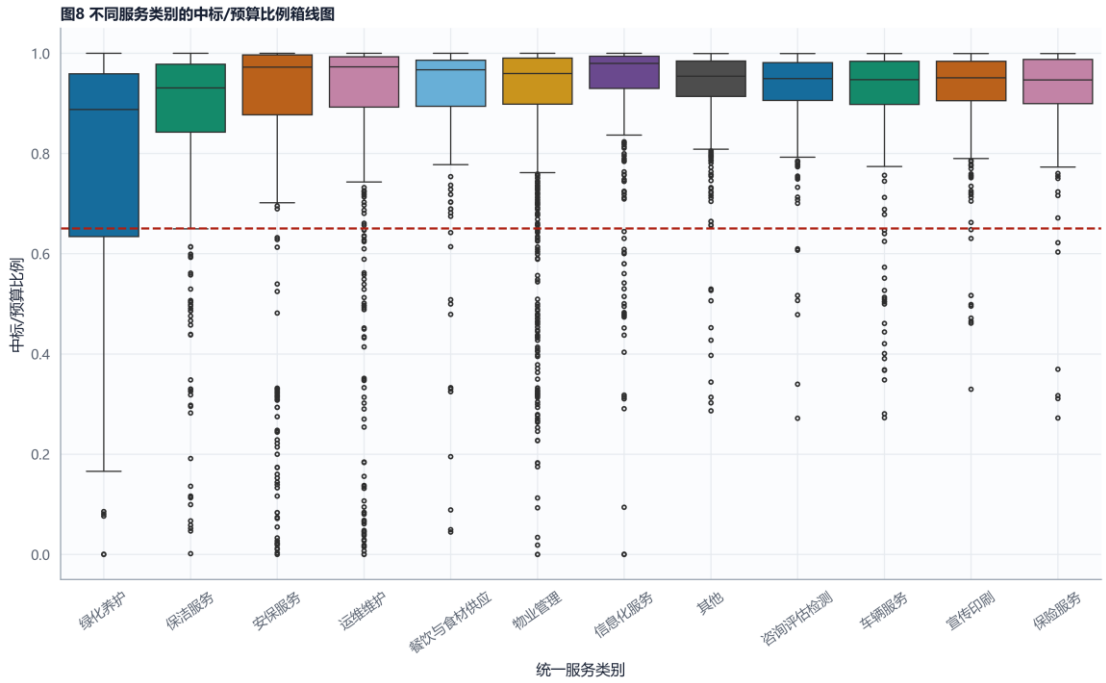


图 8 不同服务类别价格比例箱线图

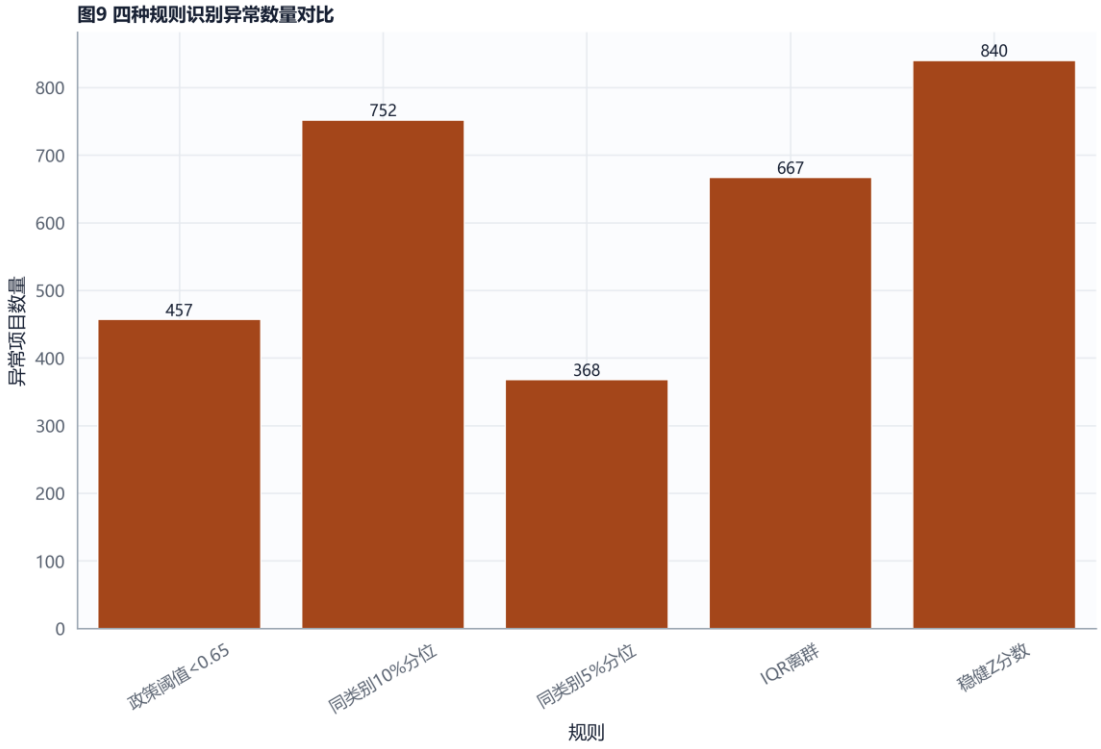


图 9 规则识别异常数量对比图

（三）综合风险等级

本文将五项规则触发结果相加，形成可复核的规则风险得分。式中，I 表示第 i 个项目是否触发相应规则的 0/1 指示变量，A_i 表示综合规则风险得分：

$$A_i = I_{i,65} + I_{i,10\%} + I_{i,5\%} + I_{i,\mathrm{IQR}} + I_{i,Z} \qquad \text{公式(5)}$$

当规则得分为 0 时定义为正常，得分为 1 时定义为低风险，得分为 2 时定义为中风险，得分大于等于 3 时定义为高风险。该规则兼顾审慎性与可解释性：只有多个规则共同指向价格显著偏低时，项目才被划入高风险类别。价格有效样本中高风险项目 649 个，占比 8.41%；服务类主样本中高风险项目 525 个，占比 9.40%。

表 5 不同服务类别风险率表（前 10 类）

统一服务类别	项目数量	规则高风险数量	高风险比例	中标预算比例中位数	平均节约率
安保服务	382	58	15.18%	0.972	15.59%
餐饮与食材供应	136	19	13.97%	0.967	11.98%
信息化服务	338	45	13.31%	0.980	9.07%
运维维护	599	67	11.19%	0.973	12.74%
宣传印刷	273	28	10.26%	0.951	8.23%
保洁服务	419	42	10.02%	0.931	13.55%
绿化养护	275	27	9.82%	0.888	22.94%
物业管理	1690	140	8.28%	0.959	9.02%

统一服务类别	项目数量	规则高风险数量	高风险比例	中标预算比例中位数	平均节约率
咨询评估检测	285	22	7.72%	0.949	7.64%
车辆服务	349	26	7.45%	0.947	9.33%

表 6 不同采购方式风险率表

采购方式标准化	项目数量	高风险数量	高风险比例
定点采购	2	1	50.00%
其他	140	17	12.14%
公开招标	4282	407	9.50%
竞争性磋商	663	49	7.39%
框架协议	587	42	7.16%
竞争性谈判	74	5	6.76%
电子卖场	1889	127	6.72%
单一来源	53	1	1.89%
询价	27	0	0.00%
邀请招标	3	0	0.00%

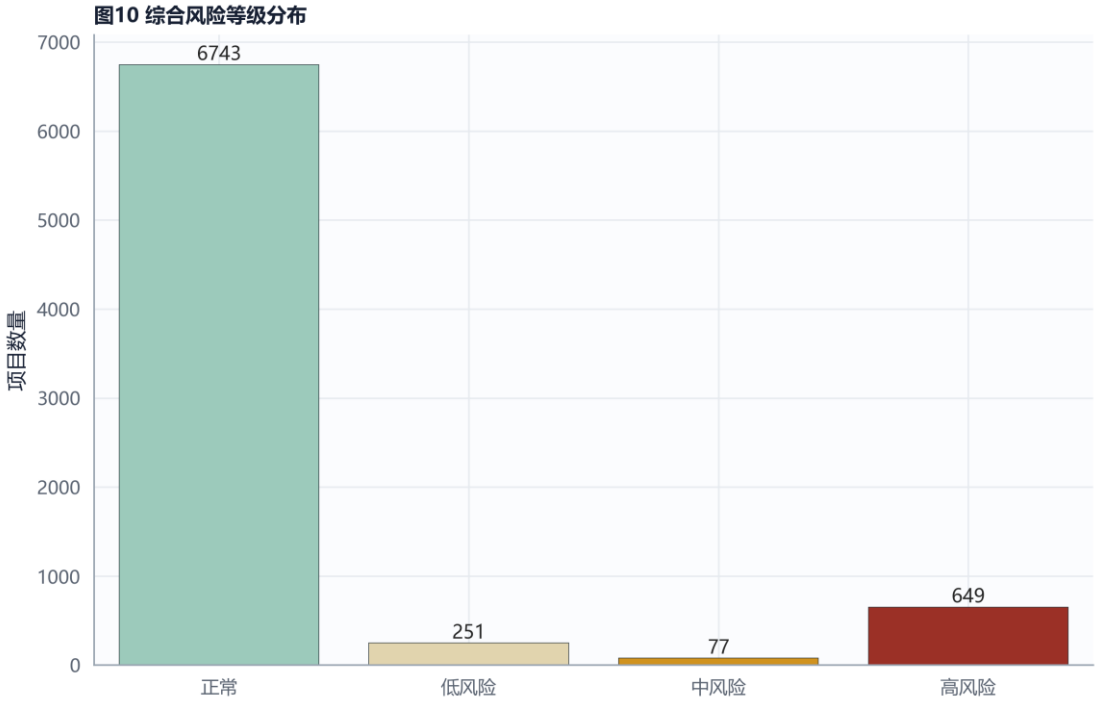


图 10 综合风险等级分布图

四、文本特征工程与项目画像构建

（一）文本预处理与 TF-IDF 特征

政府采购公告文本包含项目需求、资格条件、服务范围、履约期限和供应商信息，是识别异常低价风险的重要补充。国内研究已证明政府采购公告文本

可用于采购领域分类和供应商行为分析[1-2]，国际研究也表明文本挖掘能够揭示竞争限制和腐败风险线索[11-12,15]。本文将公告标题、项目名称、公告正文、统一服务类别和采购方式合并为文本语料，用于构造 TF-IDF 和主题特征。

文本预处理包括文本合并、字符清洗、jieba 分词、停用词删除、TF-IDF 降维和 LDA 主题提取六个环节。其中，文本合并覆盖公告标题、项目名称、公告正文、服务类别和采购方式，字符清洗保留中英文与数字信息。

TF-IDF 方法通过词频与逆文档频率的乘积衡量词项区分度[17]，适合从公告文本中抽取服务类别、技术需求和采购对象特征。本文选取高频且具有区分度的关键词，并通过截断奇异值分解获得文本主成分，用于后续异常检测和监督模型。



图 11 政府采购公告关键词词云图



图 12 高风险项目关键词词云图

（二）LDA 主题建模

为进一步刻画项目需求结构，本文采用 LDA 主题模型识别公告文本中的潜在主题。LDA 将文档视为主题混合、主题视为词项分布[18]，能够将长文本压缩为具有解释意义的主题概率变量。本文设置 6 个主题，并依据各主题 Top 关键词进行解释。为提升主题可解释性，研究在原有停用词基础上，进一步剔除城市名、日期词、联系电话和公告模板词等低信息量词项。

表 7 LDA 主题解释表

主题编号	主题关键词 Top10	项目数量	规则高风险比例
1	深圳市、深圳、质疑、投标、结果、招标、物业管理、集团、后面、街道	562	1.60%
2	日期、车辆、签订、履约、数量、甲方、单价、规格型号、乙方、编号	1467	6.34%
3	联系人、物业管理、评审、单位地址、联系电话、招标、名单、jszc、单位名称、中小企业	1779	14.05%
4	重庆市、评审、联系人、招标、结果、运维、重庆、物业、物业管理、宁夏	645	11.63%
5	投标、招标、绿化、养护、投标人、系统、电子、开标、企业、资格	298	10.74%
6	定点、电子、卖场、日期、盐城市、印刷、物业管理、数量、广州市、履约	837	7.89%



图 13 LDA 主题关键词图

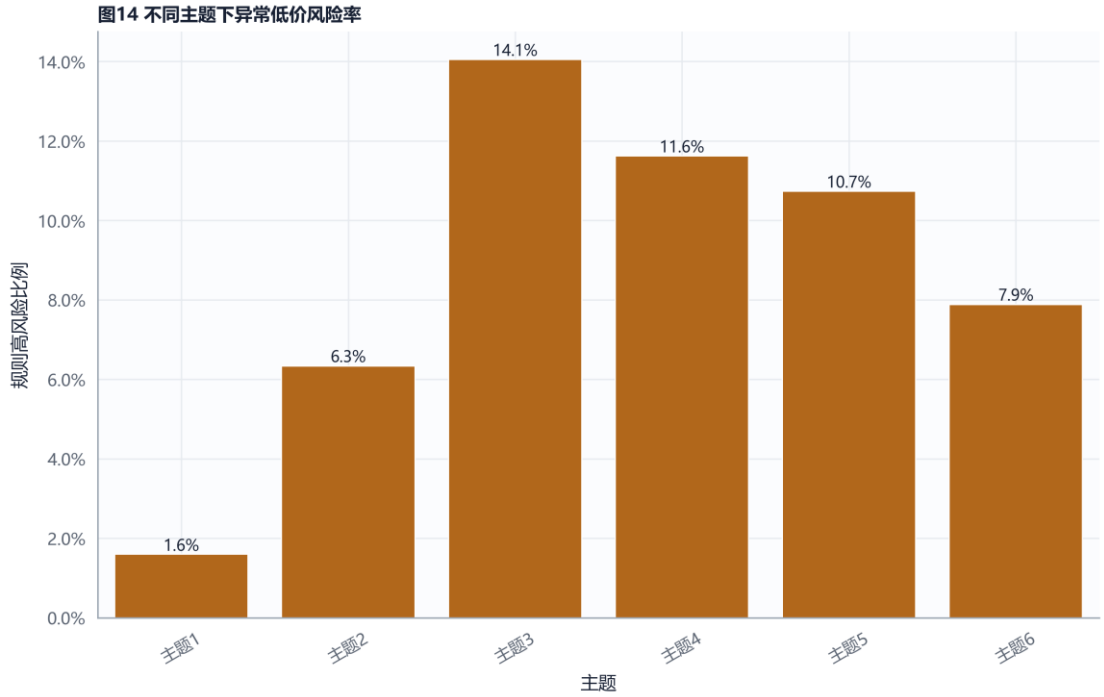


图 14 不同主题下异常低价风险率柱状图

（三）项目画像与供应商画像

项目画像包括价格画像、文本画像、采购画像、地区画像和风险画像。供应商画像重点刻画中标次数、低价中标次数、平均节约率、跨省中标比例、涉

及类别数和综合风险画像分。供应商维度能够反映重复中标、跨区域经营和低价策略倾向，为后续网络分析提供节点属性。

供应商画像从中标次数、低价中标次数、平均节约率、跨省中标比例、涉及类别数和综合风险分六个维度刻画其市场活跃度、价格行为和跨区域经营特征。

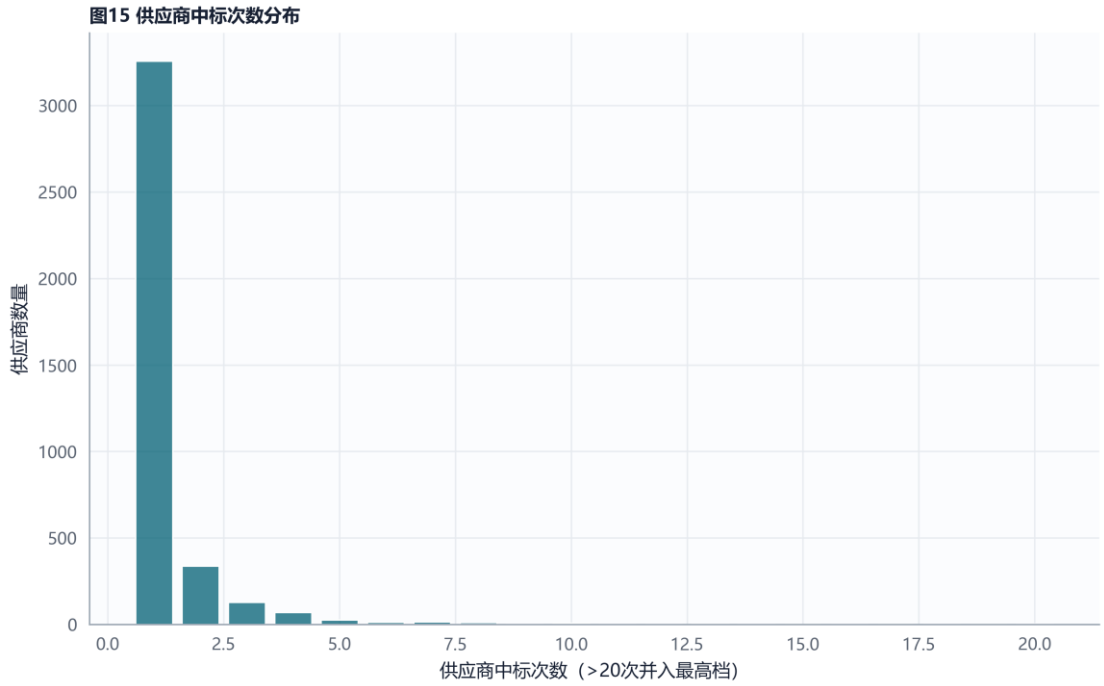


图 15 供应商中标次数分布图

五、异常低价中标风险识别模型

（一）特征体系与模型选择

异常低价风险属于小比例、弱标签和多维异常识别问题。本文以服务类主样本作为主模型样本，输入特征包括价格特征、采购特征、文本主题特征、供应商画像特征和地区宏观特征。考虑到规则标签具有不完全性，本文采用无监督/半监督异常检测模型识别潜在异常项目。Isolation Forest 通过随机切分特征空间隔离异常点[19]，LOF 基于局部密度偏离识别异常[20]，One-Class SVM 则学习正常样本边界[21]。在监管情境中，多模型集成有助于降低单一算法对分布假设和参数设定的依赖。

在异常检测模型中，Isolation Forest 侧重全局异常隔离，LOF 强调局部密度偏离，One-Class SVM 用于刻画正常样本边界；三者集成后取标准化得分的加权平均。

图16 异常检测模型流程图



图 16 异常检测模型流程图

（二）集成异常检测模型

由于各异常检测模型输出分数的尺度并不一致，本文先对 Isolation Forest、LOF 和 One-Class SVM 得分进行 0—1 标准化，再与规则风险得分融合，形成集成异常分数。式中，E_i 表示第 i 个项目的集成异常分数，A_i 表示标准化后的规则风险得分：

集成策略遵循两个原则：一是互补性，Isolation Forest 擅长识别全局偏离点，LOF 对局部密度异常更为敏感，One-Class SVM 能够捕捉高维边界外样本，三者结合可覆盖不同异常模式；二是可解释性，规则风险得分直接来源于可复核的价格阈值，将其纳入集成有助于防止纯数据驱动模型脱离业务逻辑。最终集成得分赋予规则风险得分 30%权重、Isolation Forest 30%权重、LOF 20%权重和 One-Class SVM 20%权重。

$$E_i = 0.30\,\mathrm{IF}_i + 0.25\,\mathrm{LOF}_i + 0.20\,\mathrm{OCSVM}_i + 0.25A_i \qquad \text{公式(6)}$$

本文将集成异常分数位于前 10%的服务类项目定义为模型高风险项目。该设定既保留异常检测模型对多维特征的敏感性，也避免完全脱离可解释的价格规则。

表 8 异常检测模型结果表

识别方式	高风险/异常项目数量	占比
Isolation Forest	525	9.40%
LOF	525	9.40%

识别方式	高风险/异常项目数量	占比
One-Class SVM	522	9.34%
规则高风险	525	9.40%
集成模型高风险	559	10.00%

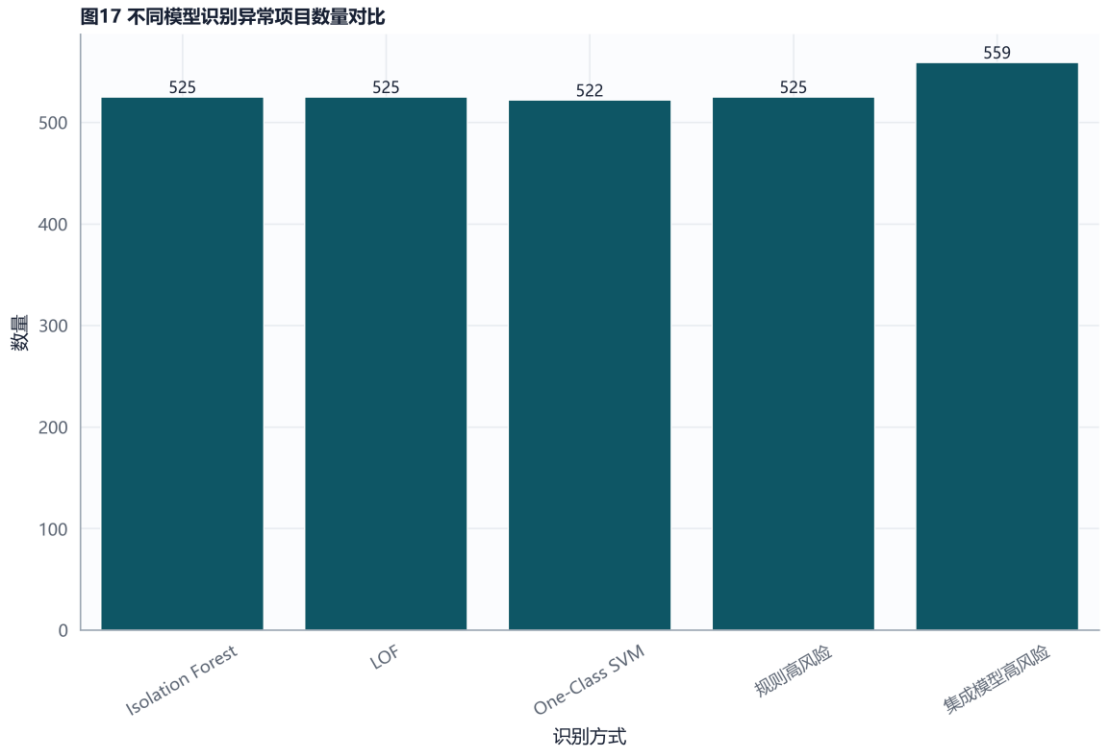


图 17 不同模型识别异常项目数量对比图

图18 异常检测模型结果重叠韦恩图

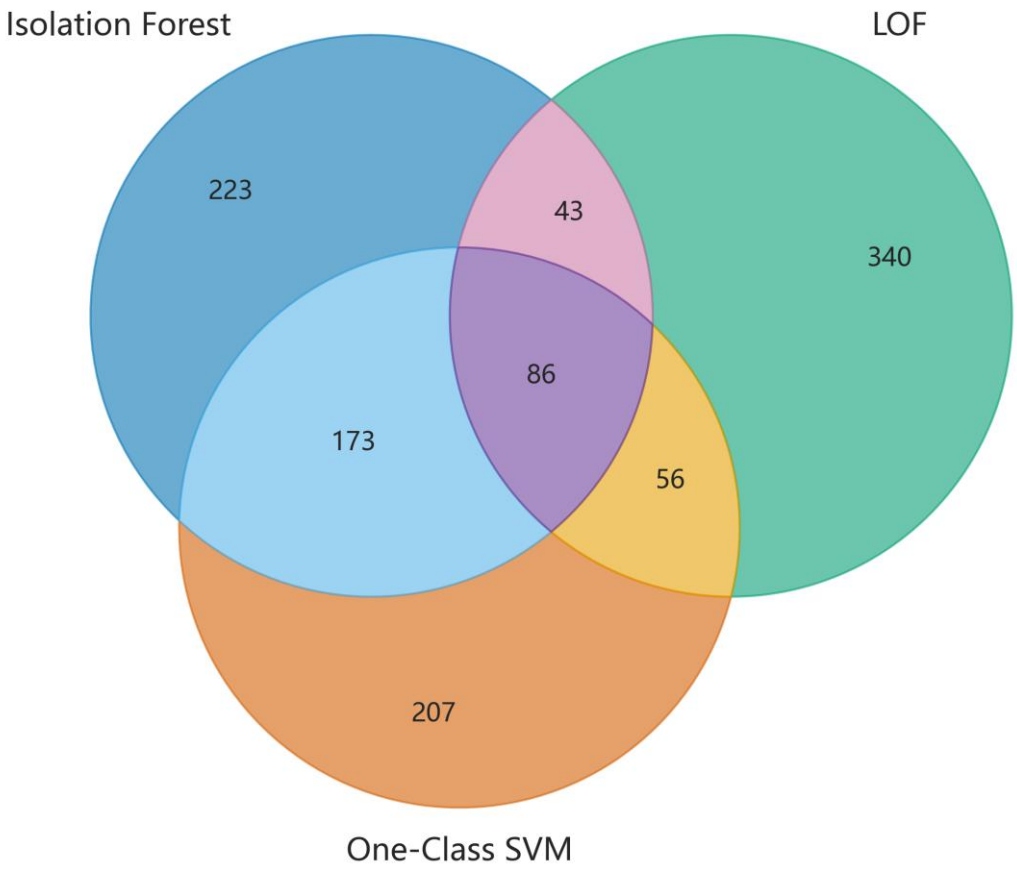


图 18 异常检测模型结果重叠韦恩图

（三）模型识别结果分析

集成异常检测模型在服务类主样本中识别高风险项目 559 个，占比 10.00%。与规则标签相比，集成模型不仅关注价格显著偏低的项目，也会识别文本需求、供应商画像和地区环境共同呈现异常的项目。从服务类别看，高风险项目集中于后勤服务、运维维护和信息化服务；从地区看，高风险项目更易在样本量较高或财政压力较大的地区聚集。总体上，模型结果为后续解释分析和监管排序提供了基础。由于高风险项目只是监管线索而非最终结论，后续仍需结合合同文本、履约记录和投诉质疑信息进行综合判断。

表 9 高风险项目统计描述表

变量	样本量	均值	中位数	标准差
price_ratio_clean	559	0.500	0.496	0.286
saving_rate_clean	559	0.500	0.504	0.286
预算金额	559	1,010,529,590	2,690,000	23,408,853,976
中标金额	559	2,909,945	900,000	8,883,745
text_length	559	1,504	1,542	1,186

变量	样本量	均值	中位数	标准差
supplier_win_count	559	3.746	1.000	5.463
supplier_low_price_rate	559	0.646	1.000	0.401
fiscal_pressure	469	1.827	1.524	0.677
average_wage	469	136,645	129,220	37,985
tertiary_industry_share	469	57.466	54.2	9.873

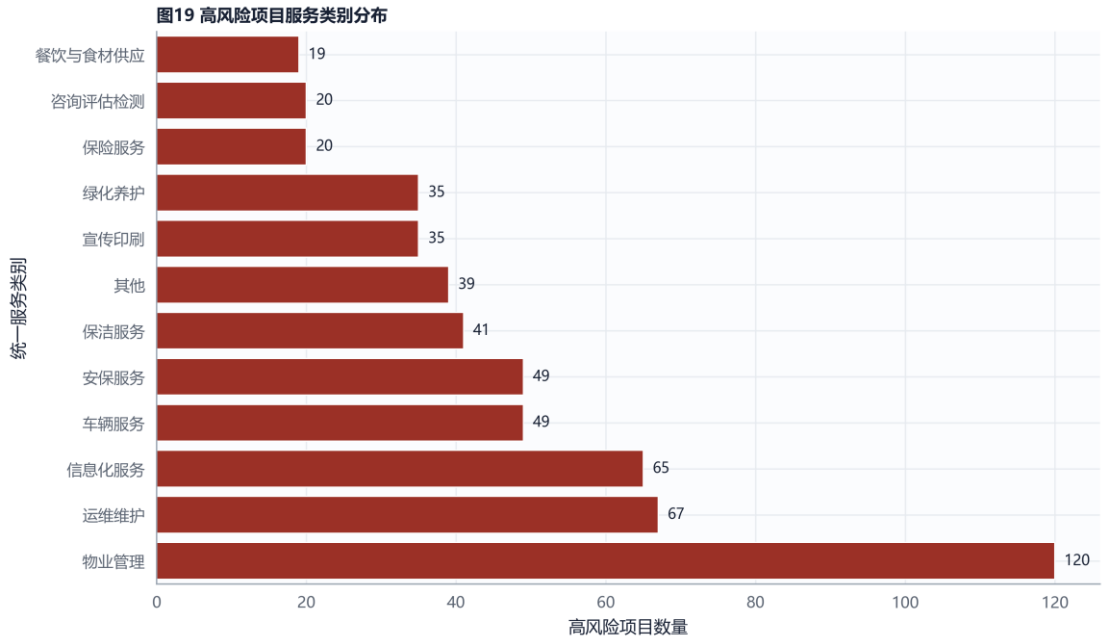


图 19 高风险项目服务类别分布图

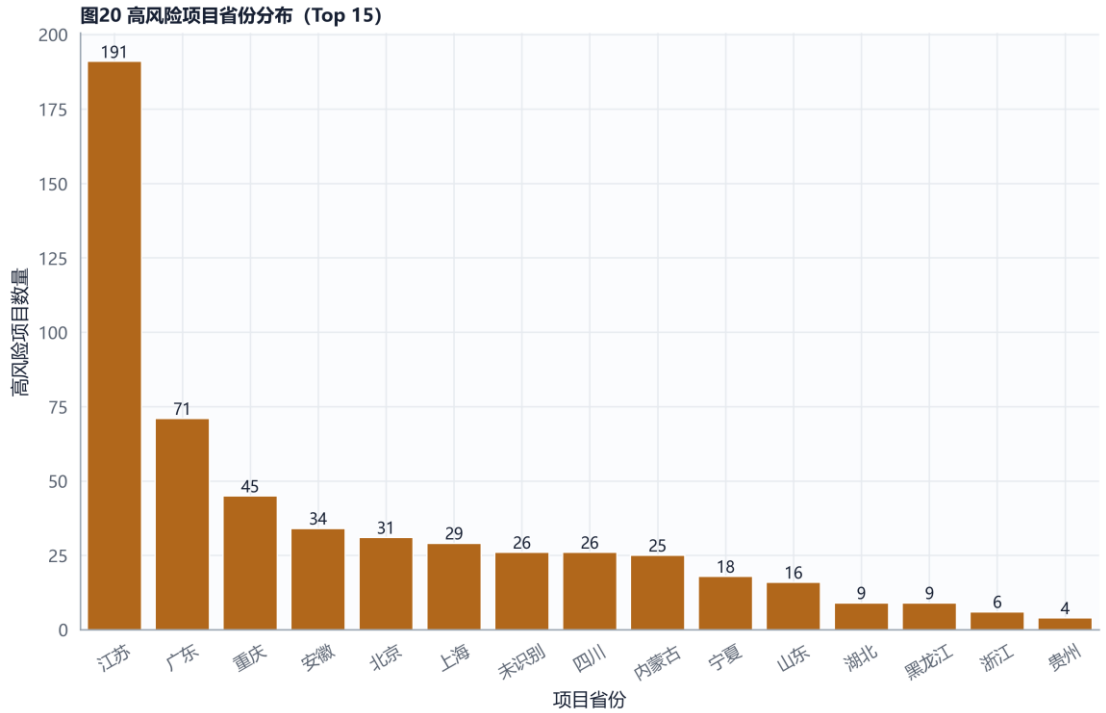


图 20 高风险项目省份分布图

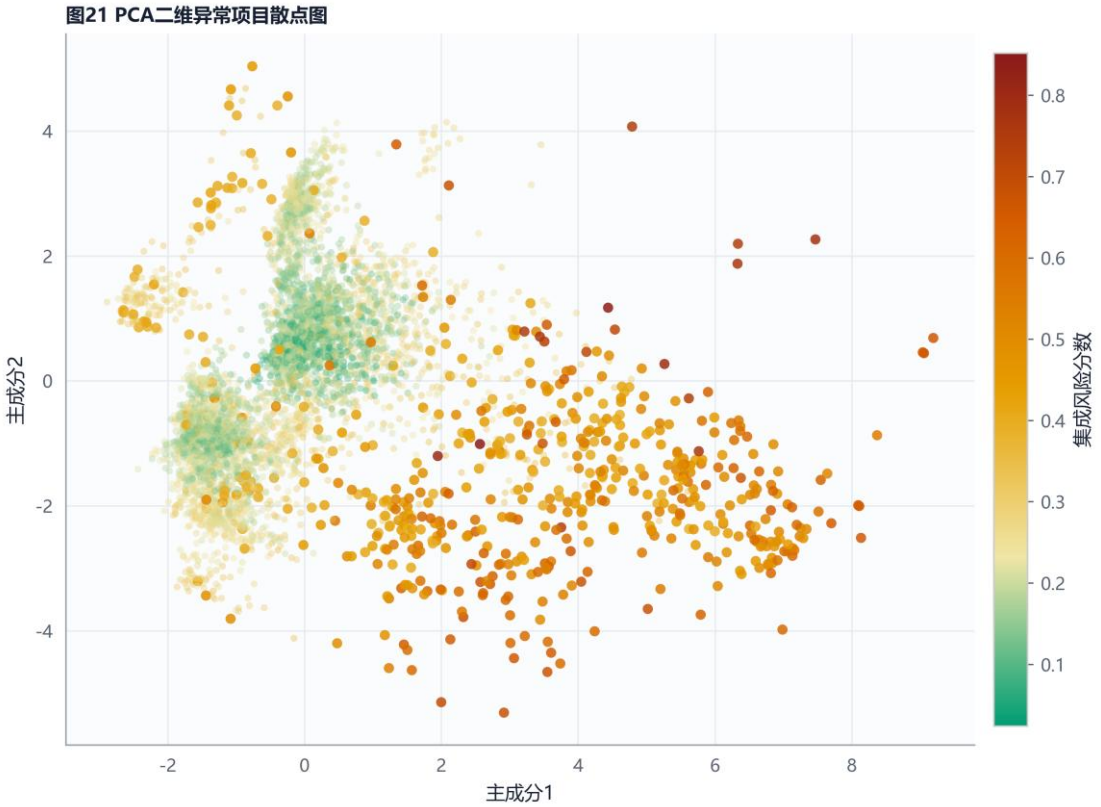


图 21 PCA 二维异常项目散点图

六、风险因素解释与风险线索组合分析

（一）监督模型评价

异常检测模型给出风险识别结果后，仍需回答“为什么这些项目被识别为高风险”。因此，本文以 final_high_risk 为目标变量，构建 Logistic 回归、Random Forest 和 XGBoost 监督模型。Logistic 回归用于观察变量方向和统计解释，Random Forest 用于非线性变量重要性对照[22]，XGBoost 用于刻画复杂非线性关系[23]。通过多模型比较，可以检验风险标签在特征空间中的可解释程度。

表 10 监督模型评价结果表

模型	Accuracy	Precision	Recall	F1	AUC
Logistic	0.955	0.706	0.943	0.807	0.992
Random Forest	0.976	0.844	0.929	0.884	0.993
XGBoost	0.974	0.837	0.914	0.874	0.991

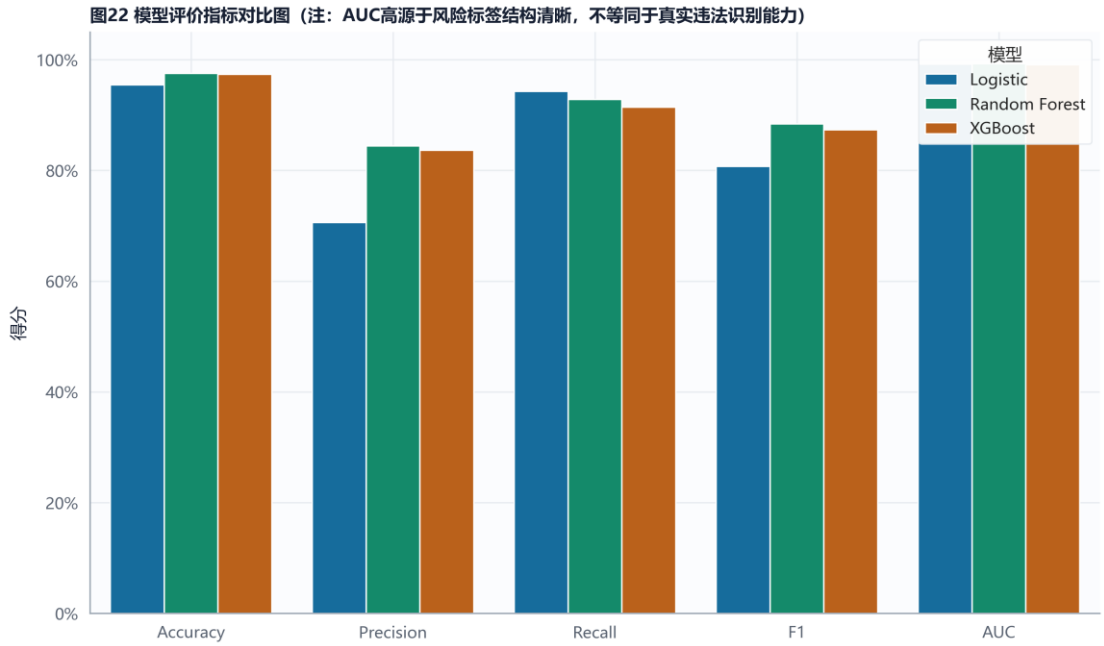


图 22 模型评价指标对比图

结果显示，XGBoost 模型 AUC 达到 0.991、F1 值为 0.874。需要说明的是，该 AUC 处于较高水平，主要因为目标变量来源于规则风险与异常检测标签，而非经执法或审计确认的真实违法标签；模型学习的实质是风险标签在特征空间中的分布结构。因此，较高 AUC 说明模型能够较好复现并排序风险标签，但不能直接等同于识别真实违法行为。后续监管应用中，应将模型评价结果理解为预警排序能力，而非行政认定准确率。

（二）Logistic 回归与变量重要性

表 11 Logistic 回归结果表

变量	系数	p 值	优势比 OR
const	-5.188	0.000	0.006
saving_rate_clean	2.831	0.000	16.966
text_length	-0.511	0.007	0.600
supplier_win_count	0.702	0.000	2.019
supplier_low_price_rate	1.198	0.000	3.315
supplier_cross_province_rate	1.28	0.000	3.598
supplier_category_count	0.293	0.017	1.34
fiscal_pressure	0.457	0.000	1.579
average_wage	0.076	0.683	1.079
tertiary_industry_share	1.032	0.000	2.807
跨省中标	-0.363	0.207	0.696
公开招标	-0.81	0.000	0.445

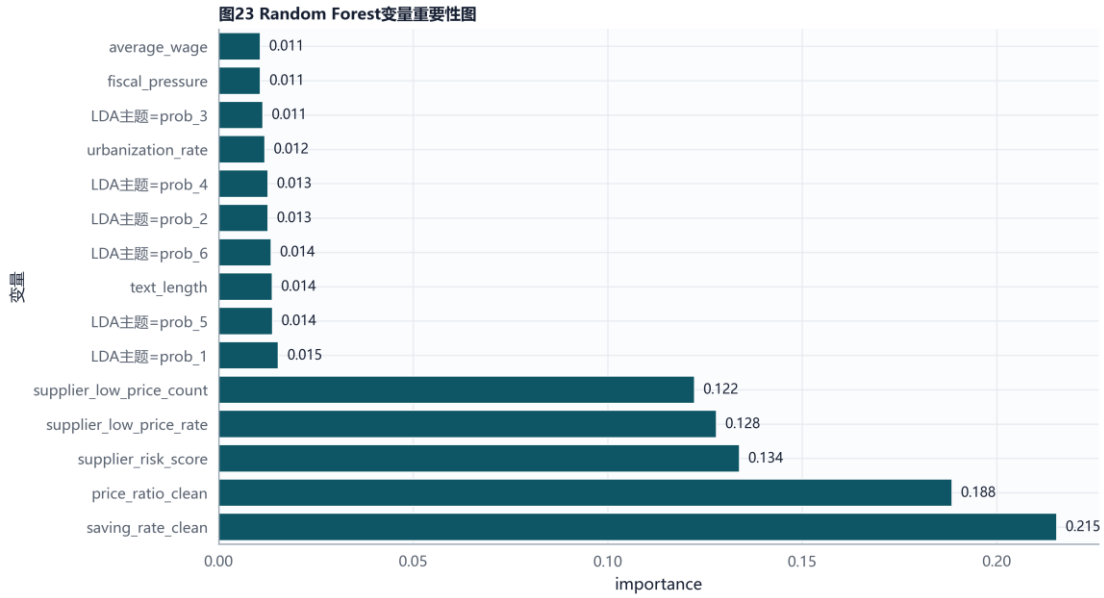


图 23 Random Forest 变量重要性图

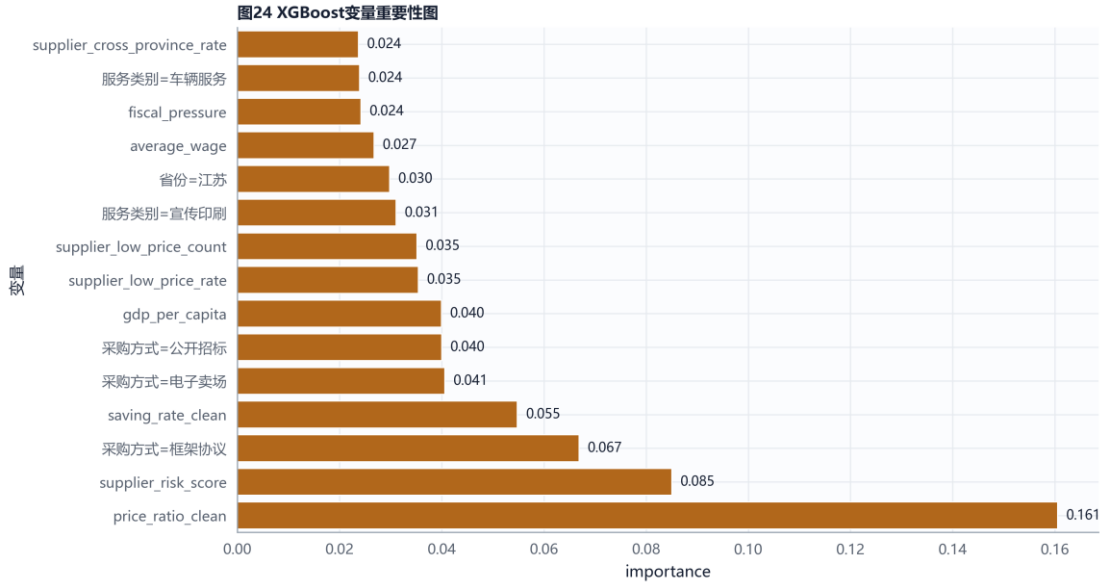


图 24 XGBoost 变量重要性图

（三）SHAP 解释

为解释 XGBoost 模型中单个变量的边际贡献，本文引入 SHAP 方法。SHAP 基于 Shapley 值思想，将模型输出分解为各特征的贡献份额，能够同时提供全局重要性和局部解释[24]。在政府采购监管场景下，SHAP 的价值在于将黑箱模型输出转化为可供人工复核的风险证据链。

表 12 SHAP 重要变量排序表

变量	mean_abs_SHAP
price_ratio_clean	1.965
supplier_risk_score	1.393

变量	mean_abs_SHAP
saving_rate_clean	0.656
fiscal_pressure	0.369
gdp_per_capita	0.353
采购方式=公开招标	0.336
LDA 主题=prob_3	0.335
text_length	0.319
supplier_cross_province_rate	0.260
LDA 主题=prob_4	0.244
LDA 主题=prob_2	0.225
average_wage	0.169

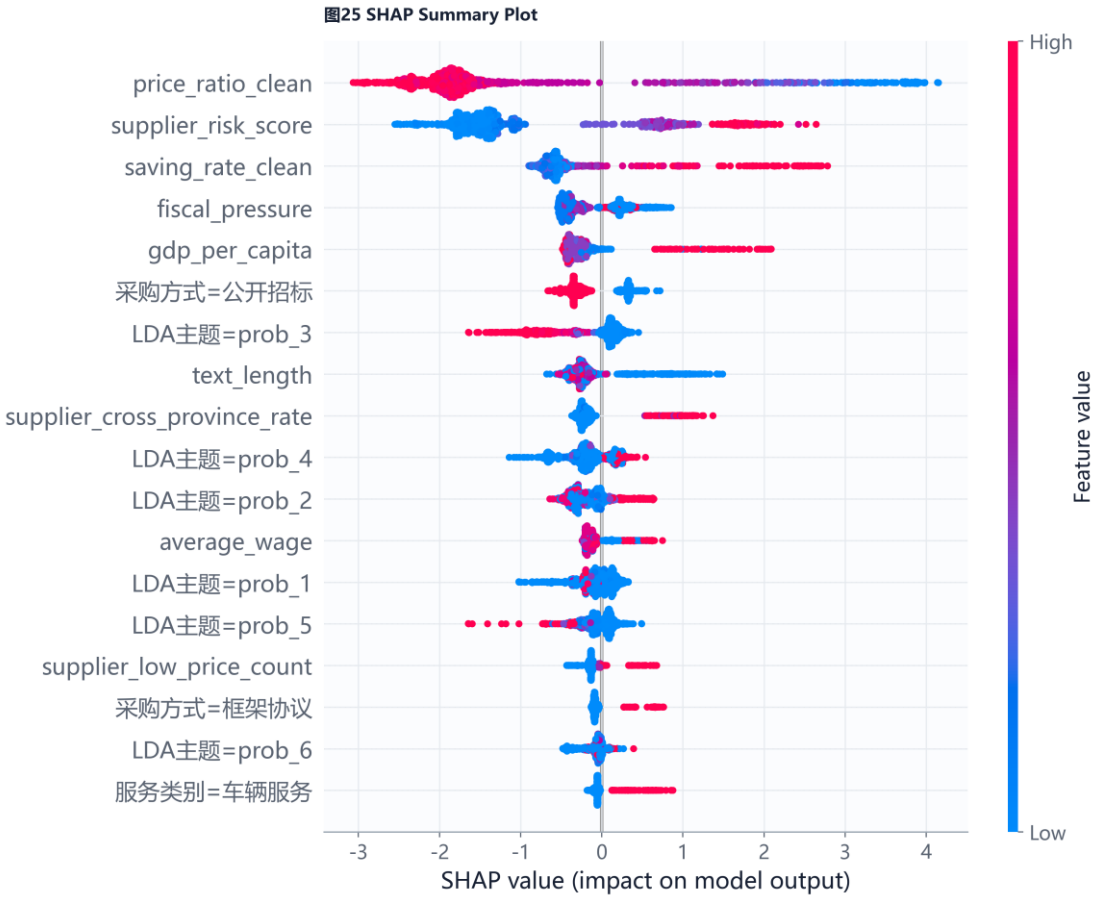


图 25 SHAP Summary Plot

图26 SHAP Dependence Plot（Top 4变量）

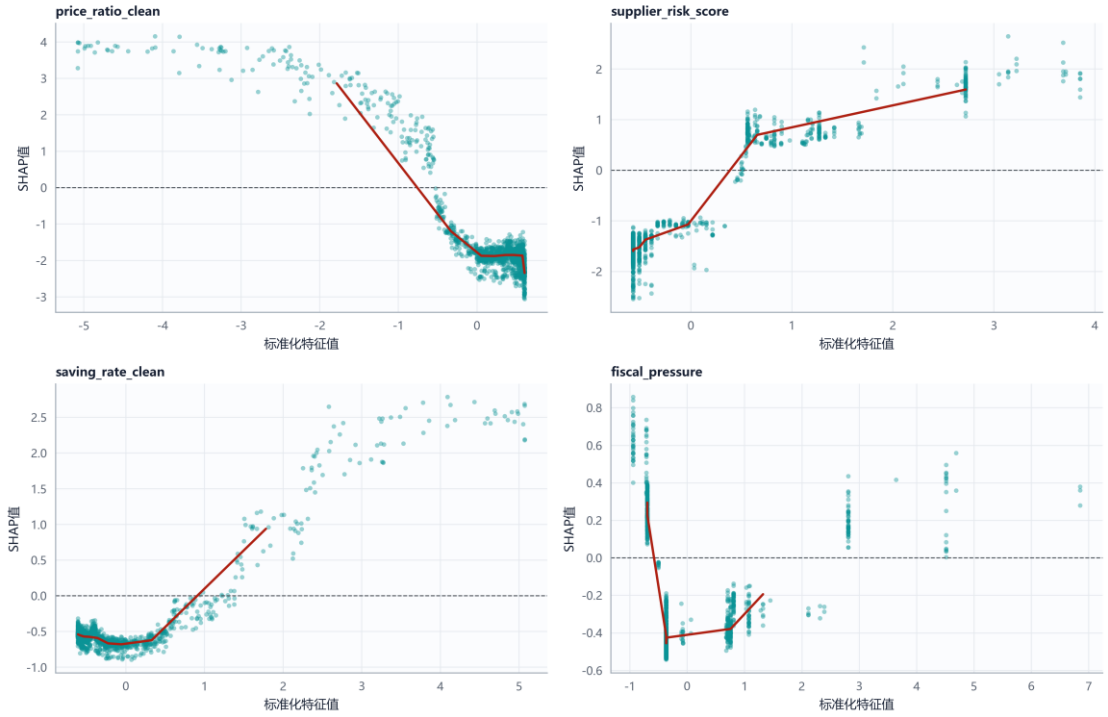


图 26 SHAP Dependence Plot

SHAP 结果显示，影响模型输出的前五个变量为 price_ratio_clean、supplier_risk_score、saving_rate_clean、fiscal_pressure 和 gdp_per_capita。其中，price_ratio_clean 和 saving_rate_clean 直接反映价格偏离程度；supplier_risk_score 体现供应商历史低价行为和风险积累；fiscal_pressure 和 gdp_per_capita 则揭示地区财政约束与经济发展水平可能对采购价格形成的影响。该结果表明，异常低价风险既受项目价格因素驱动，也受供应商行为和地区环境共同影响。

从监管应用角度看，SHAP 输出的核心价值在于把黑箱预测转化为可复核证据。例如，当某项目被模型判定为高风险时，SHAP 可分解出 price_ratio_clean 对风险得分的正向贡献，同时显示 fiscal_pressure 和 supplier_risk_score 是否进一步放大风险。这种分解结果可写入监管平台预警摘要，帮助监管人员快速定位复核重点。

（四）QCA 探索性风险线索组合

异常低价风险往往不是单一变量造成，而是多条件并发的结果。本文借鉴 fsQCA 方法[25]，将高节约率、低价格比例、高频供应商、跨省中标、高财政

压力、公开招标、供应商信息缺失和高风险服务类别等变量转化为集合条件，分析其与高风险结果之间的组合关系。

表 13 QCA 探索性风险线索组合路径表

路径编号	成因组合	案例数	高风险案例数	一致性	覆盖度
路径 1	高节约率 × 低价格比例 × 跨省中标 × 公开招标 × 高风险服务类别	8	7	0.875	0.013
路径 2	高节约率 × 低价格比例 × 高频供应商 × 高财政压力 × 高风险服务类别 × 非跨省中标 × 非公开招标	34	23	0.676	0.041
路径 3	高节约率 × 低价格比例 × 跨省中标 × 高财政压力 × 公开招标 × 高风险服务类别	10	6	0.600	0.011
路径 4	高节约率 × 低价格比例 × 高频供应商 × 高财政压力 × 公开招标 × 高风险服务类别 × 非跨省中标	60	29	0.483	0.052



图 27 QCA 成因路径图

QCA 结果显示，异常低价风险呈现多条探索性线索：路径 1 的一致性相对较高，可视为较稳健的风险组合；路径 2—路径 4 的一致性偏低，更适合作为引导后续复核的探索性线索，不宜直接解释为严格因果结论。总体看，价格偏离是出现频率最高的核心线索，高频供应商、高财政压力、跨省中标、特定采购方式和高风险服务类别等条件的组合，能够进一步提高风险识别的针对性。

七、采购关系网络与风险聚集分析

（一）网络构建

公共采购风险具有明显的关系嵌入性。供应商与采购人之间的重复交易、核心主体位置和社群结构，可能反映市场进入壁垒、信息不对称或监管盲区。网络分析文献指出，公共采购欺诈和腐败风险可以通过主体连接结构、中心性

和社群发现获得线索[16]。本文构建供应商—采购人二部关系网络，节点包括供应商和采购人，边表示中标交易关系，边权为交易项目数量。

供应商—采购人二部网络以统一供应商名称和采购人名称为节点，以中标交易关系为边，边权为交易项目数量；网络指标包括加权度、度中心性、介数中心性、特征向量中心性和 Louvain 社群。

图28 采购关系网络总体图（核心节点）

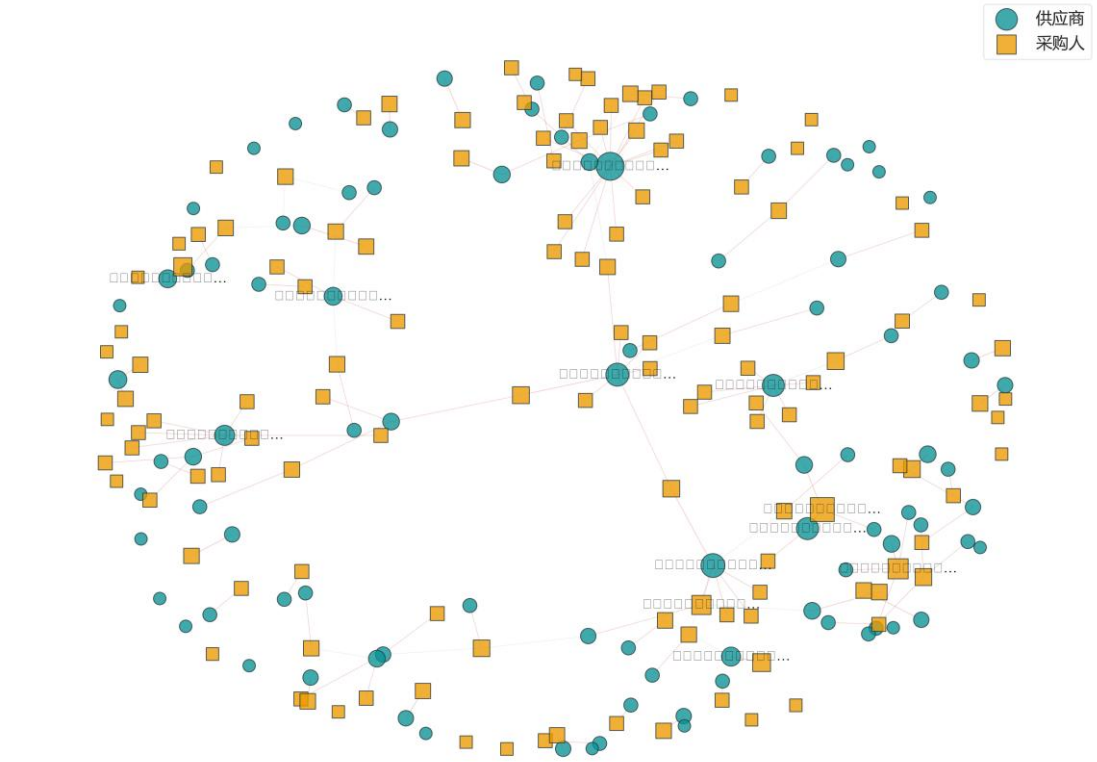


图 28 采购关系网络总体图

（二）高风险主体识别

本文计算加权度、度中心性、介数中心性和特征向量中心性，并结合关联高风险项目数量和高风险比例识别监管重点。供应商中心性排名反映其在交易网络中的活跃度和核心位置，采购人风险排名则反映其关联项目中高风险项目占比。

表 14 高风险供应商排名表（前 10）

主体名称	项目数量	高风险项目数量	高风险比例	特征向量中心性	主服务类别
中国石油天然气股份有限公司四川成都销售分公司	16	15	0.938	0.000	车辆服务

主体名称	项目数量	高风险项目数量	高风险比例	特征向量中心性	主服务类别
江苏移动信息系统集成有限公司	26	8	0.308	0.002	信息化服务
中电鸿信信息科技有限公司	22	8	0.364	0.002	运维维护
南京春满园物业管理有限公司	17	6	0.353	0.000	物业管理
江苏营财安保股份有限公司	12	6	0.500	0.000	安保服务
中国人寿财产保险股份有限公司上海市分公司	5	5	1.000	0.000	保险服务
镇江华舟物业管理有限公司	4	4	1.000	0.000	物业管理
阿拉善右旗鑫通泰汽车修理厂	3	3	1.000	0.174	车辆服务
常州金坛金盛物业管理有限公司	4	3	0.750	0.000	物业管理
苏州市东吴保安服务有限公司	6	3	0.500	0.000	安保服务

表 15 高风险采购单位排名表（前 9，已剔除疑似联系人字段）

主体名称	项目数量	高风险项目数量	高风险比例	特征向量中心性	主服务类别
溧阳市人民政府古县街道办事处	4	4	1.000	0.000	物业管理
重庆市渝北区人民政府天宫殿街道办事处	4	4	1.000	0.000	物业管理
阜宁县民政局（机关）	3	3	1.000	0.001	信息化服务
太仓市公安局(本级)	3	3	1.000	0.000	信息化服务
太仓市人民政府娄东街道办事处	3	3	1.000	0.000	运维维护
丰都县人民医院	2	2	1.000	0.000	物业管理
句容市人民医院	2	2	1.000	0.000	物业管理
苏州市太仓生态环境局(本级)	2	2	1.000	0.000	运维维护
宝应县人民医院	2	2	1.000	0.000	物业管理

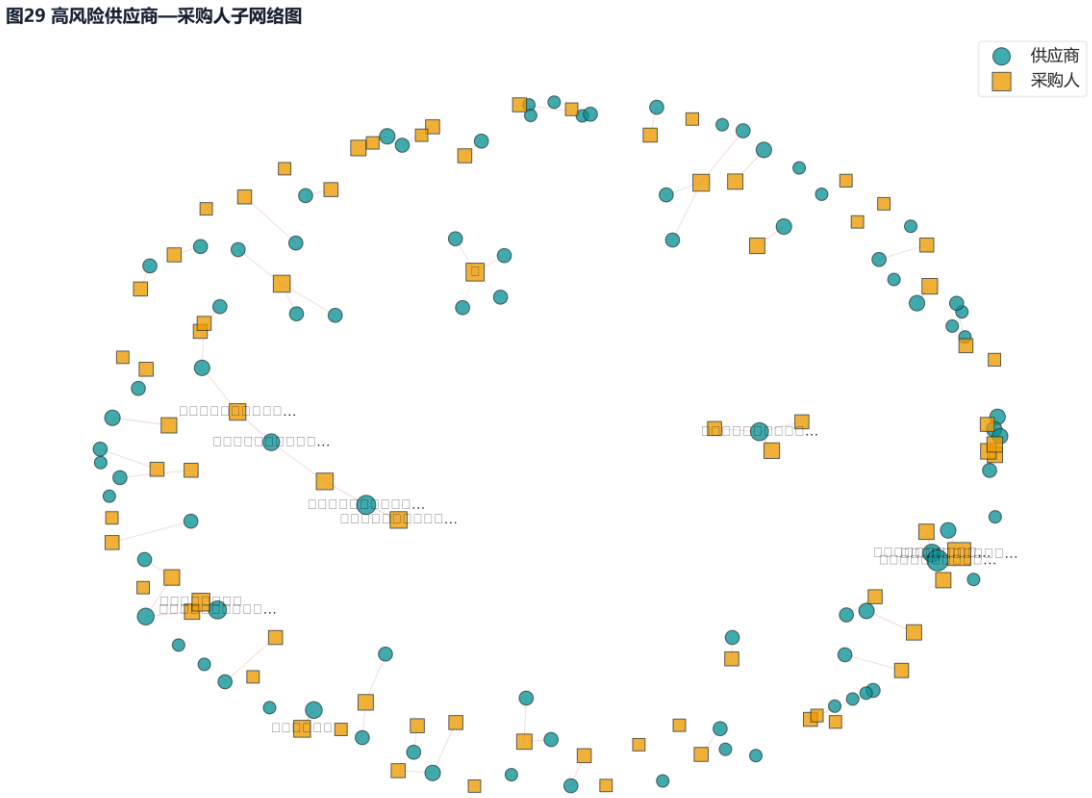


图 29 高风险供应商—采购人子网络图

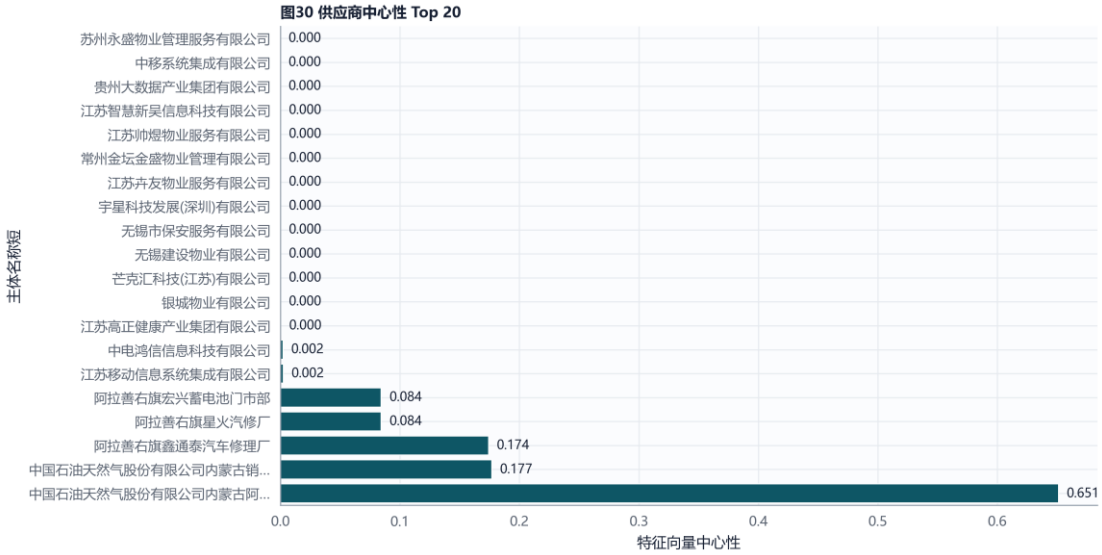


图 30 供应商中心性 Top 20 条形图

（三）风险社群分析

表 16 高风险社群特征表（前 10）

社群	节点数量	供应商数量	采购人数量	关联项目数量	高风险项目数量	高风险比例
186	4	1	3	10	10	1.000
2,003	5	2	3	10	10	1.000

社群	节点数量	供应商数量	采购人数量	关联项目数量	高风险项目数量	高风险比例
858	5	4	1	8	8	1.000
2,435	5	4	1	8	8	1.000
770	4	1	3	6	6	1.000
952	4	2	2	6	6	1.000
1,996	3	2	1	6	6	1.000
2,621	3	2	1	6	6	1.000
95	3	2	1	4	4	1.000
119	3	2	1	4	4	1.000

核心主体名单较长，正文仅呈现社群规模、交易项目数和高风险比例等结构特征；具体供应商和采购人可结合表 14、表 15 的中心性排名追踪。对于项目数较少但风险比例为 100%的主体，需要特别注意：小样本下 100%高风险并不意味着主体必然存在问题，可能源于偶然中标或规则阈值恰好触发。此类主体更适合作为重点复核线索，应通过增加样本观察、核验履约资料和比对历史交易进一步判断。

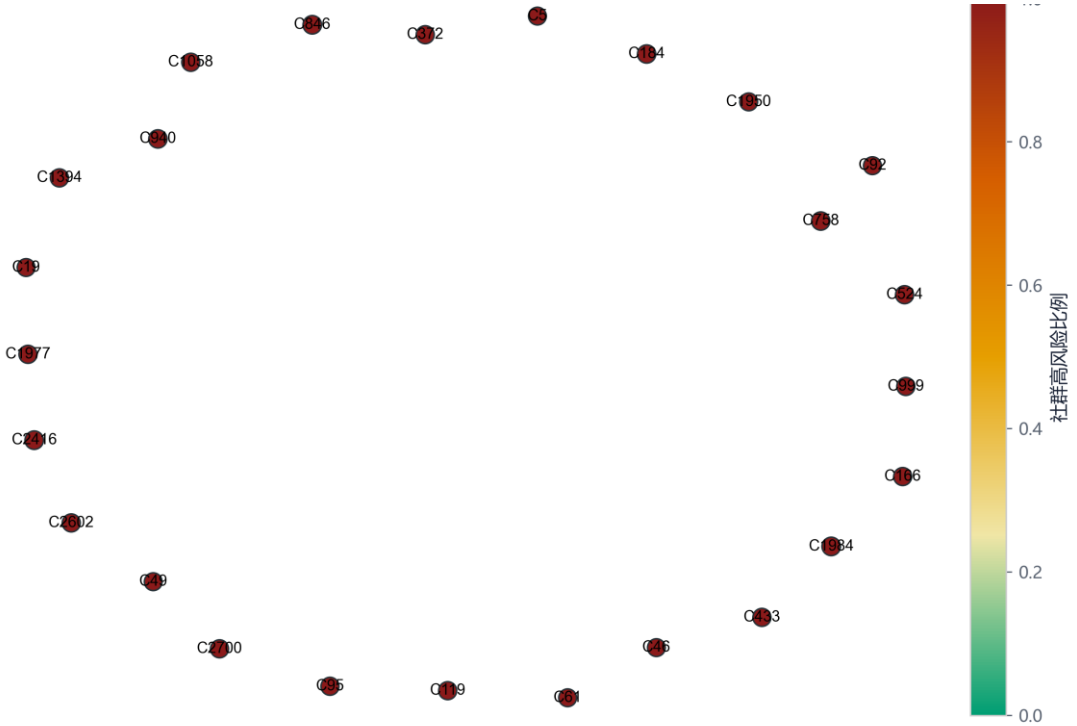


图 31 风险社群网络图

社群分析表明，高风险项目并非完全随机分散，而是在若干供应商—采购人交易群体中呈现聚集。对于监管部门而言，社群结果可用于形成“项目—主体—类别—地区”的联动审查清单：当某一社群同时具有高交易密度、高风险比例

和核心供应商重复出现等特征时，应优先开展合同履约、报价合理性和供应商资质复核。网络证据的价值不在于单独证明违规，而在于帮助监管部门识别需要连续观察的主体组合。

八、稳健性检验与扩展分析

（一）扩展样本规则稳健性

为检验规则与模型结论是否具有样本外稳定性，本文使用 2025Q1 扩展样本进行稳健性检验。扩展样本来自合同公告，项目类型覆盖服务、货物、工程和其他类别，能够与服务类主样本形成互补。异常低价研究文献强调，不同制度环境和项目类型下的低价判断应进行样本外验证[9-10]。

表 17 稳健性检验结果表

样本类型	样本量	规则高风险比例	模型高风险比例	中标/预算比例中位数	平均节约率
服务类主样本	5588	0.094	0.100	0.955	0.106
2025Q1 扩展样本	4500	0.065	—	0.953	0.073

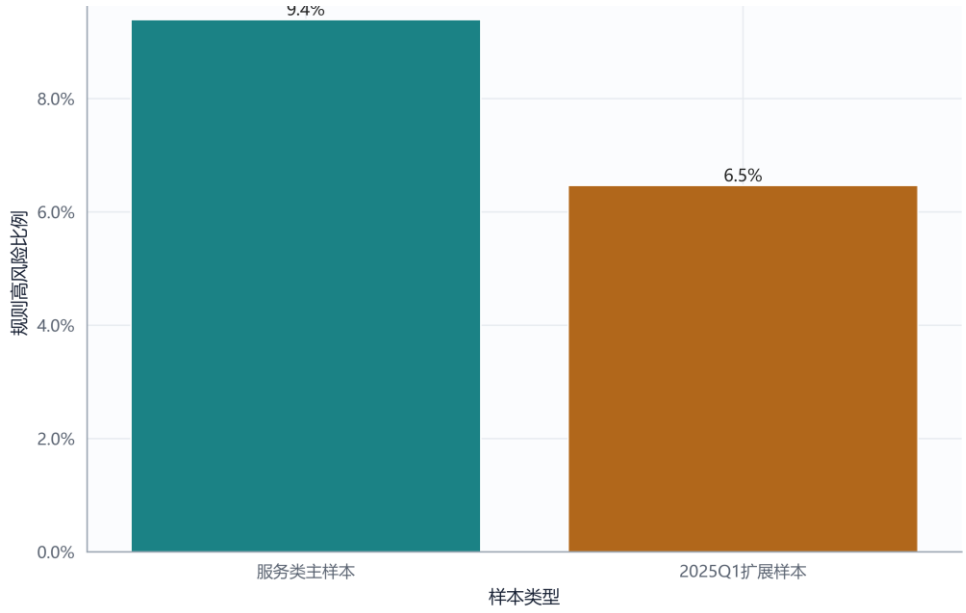


图 32 主样本与扩展样本风险率对比图

（二）采购大类比较与阈值敏感性

扩展样本中规则高风险比例为 6.47%，低于服务类主样本，但主要风险方向仍与价格偏离、服务类别差异和供应商行为有关。采购大类比较显示，服务、货物和工程项目的风险率存在差异，说明异常低价审查阈值不宜完全统一。需

要说明的是，扩展样本来自合同公告，缺少部分供应商画像字段和代理机构信息，因此不完全等同于主样本建模场景，其结果主要用于检验规则方向和结论稳健性。该结果也提示，跨数据源应用模型时应关注字段口径、公告类型和样本结构差异。

表 18 采购大类风险率对比表

采购大类	项目数量	高风险数量	价格比例中位数	高风险比例
服务类	2358	166	0.950	0.070
工程类	321	22	0.958	0.069
其他	74	5	0.945	0.068
货物类	1747	98	0.957	0.056

表 19 阈值敏感性分析表

阈值类型	阈值设置	识别数量	识别比例
固定阈值	price_ratio < 0.60	97	0.022
固定阈值	price_ratio < 0.65	112	0.025
固定阈值	price_ratio < 0.70	129	0.029
同类别分位数	低于 5%分位	233	0.052
同类别分位数	低于 10%分位	458	0.102
同类别分位数	低于 15%分位	679	0.151

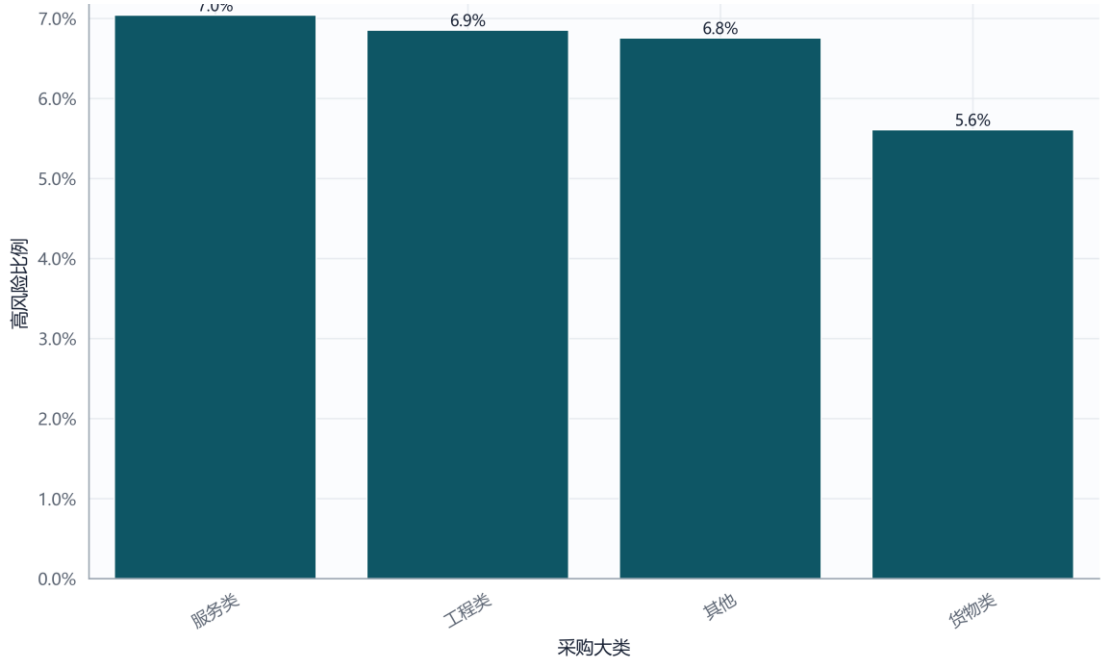


图 33 服务类、货物类、工程类风险率对比图

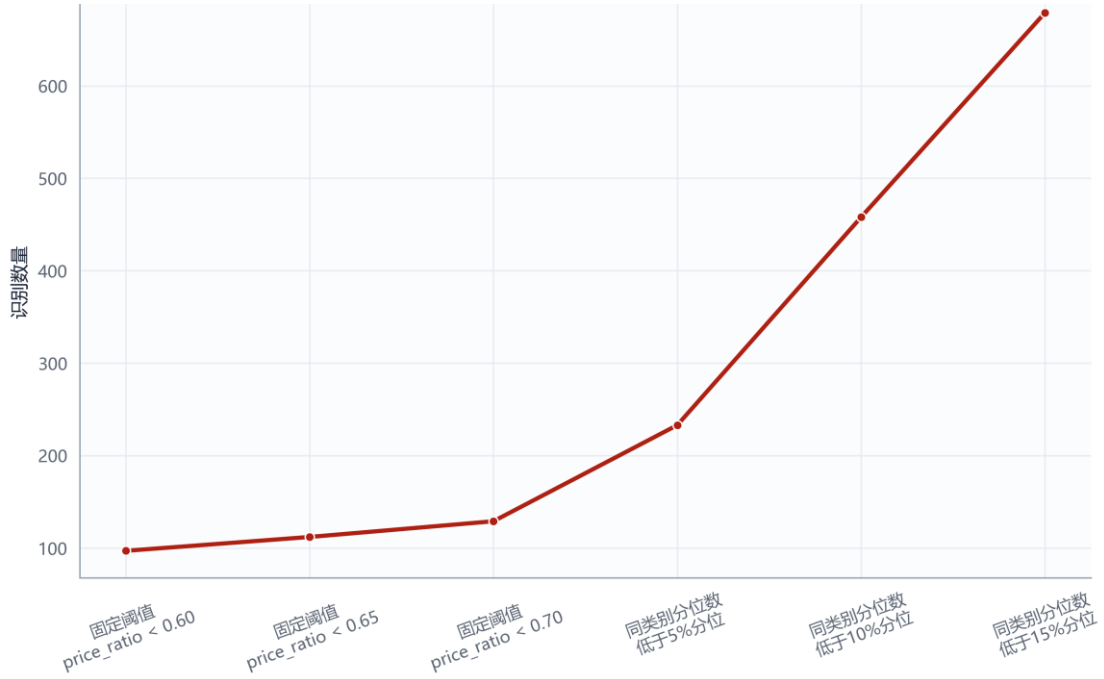


图 34 不同阈值下高风险项目数量变化图

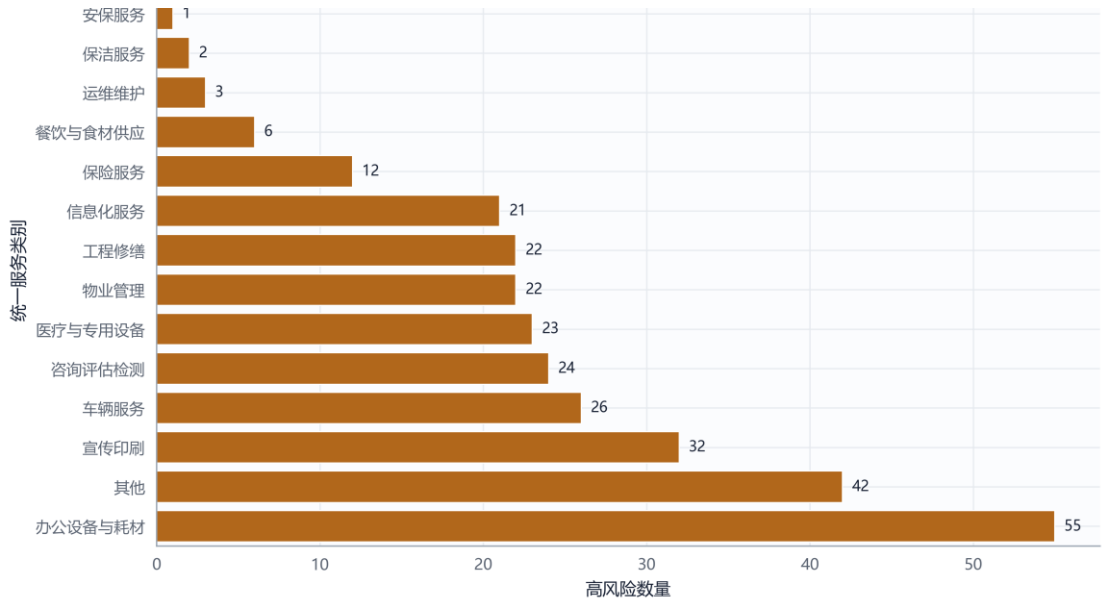


图 35 扩展样本高风险服务类型分布图

阈值敏感性结果表明，当固定阈值由 0.60 放宽至 0.70 时，识别数量明显增加；类别分位数由 5%提高到 15%时，预警范围同样扩大。这说明规则阈值本质上是监管资源配置参数：阈值越宽松，覆盖面越大但复核成本越高；阈值越严格，误报较少但可能遗漏边界风险。本文建议在正式监管中采用“基础阈值+类别阈值+模型排序”的组合方式，而非依赖单一固定阈值。

九、结论与政策建议

（一）研究结论

本文基于政府采购公告、合同扩展样本和省级宏观指标，构建异常低价风险识别与监管决策模型，并从价格规则、机器学习解释和关系网络三个层面开展验证，得到以下主要结论和监管治理启示，可归纳如下：

第一，异常低价风险具有显著类别差异。服务类项目是主样本主体，不同统一服务类别的中标/预算比例分布和高风险比例存在差异，说明统一阈值难以覆盖不同服务的成本结构。

第二，价格偏离、节约率和供应商风险画像是异常低价识别的核心因素。SHAP 结果显示，price_ratio_clean、saving_rate_clean 和 supplier_risk_score 对模型输出影响最大，验证了价格规则与供应商历史行为结合的必要性。

第三，地区宏观环境具有解释作用。财政压力和人均 GDP 进入 SHAP 前列，表明地方财政约束和经济发展水平可能影响采购预算约束、供应商竞争格局和低价中标策略。

第四，异常低价风险具有组态成因。QCA 结果显示，高节约率、低价格比例、高频供应商、跨省中标、高财政压力和高风险服务类别之间存在多种组合路径，单因素解释并不充分。

第五，风险存在网络聚集特征。供应商—采购人网络揭示了核心主体、高风险采购单位和风险社群，为监管部门由单项目审查转向主体关系治理提供了依据。

本研究的局限也需要正视：一是异常低价标签本质上是基于统计规则和异常检测的风险标签，而非经审计或司法确认的真实违法标签，模型输出只能作为预警线索；二是公告文本长度和字段完整性存在差异，部分项目的文本特征可能受公告模板影响而出现系统性偏差；三是关系网络仅覆盖单一时期截面数据，无法捕捉供应商进入、退出和关系断裂的动态过程；四是扩展样本字段与主样本并不完全一致，稳健性检验仍受到数据可得性限制。因此，本文结论更适合解释异常低价风险的结构性特征和监管优先级，而不宜被理解为对具体主体的直接责任认定。

（二）政策建议

表 20 政策建议对应模型依据表

政策建议	模型依据	对应章节
建立异常低价自动预警机制	规则得分、集成风险分数、阈值敏感性分析	第三章、第五章、第八章
按采购类别设置差异化审查阈值	服务类别风险率、箱线图、主题风险率	第三章、第四章
建立供应商低价中标画像机制	供应商中标次数、低价次数、网络中心性	第四章、第七章
加强高风险采购方式和高风险地区监管	采购方式/省份风险率、宏观变量解释	第三章、第六章
建立中标后履约跟踪机制	高风险项目名单、关系网络社群	第五章、第七章

第一，建立异常低价自动预警机制。监管平台可实时计算中标/预算比例、节约率、类别偏离度和规则风险得分，并结合异常检测模型输出形成项目风险

排序。对于多规则触发或模型得分位于高分位的项目，应纳入人工复核清单。预警结果应同时展示触发规则、关键变量贡献和历史同类项目价格区间，以便提高复核效率和解释透明度。

第二，按采购类别设置差异化审查阈值。物业管理、绿化养护、信息化、运维维护、咨询评估检测等服务类型的成本结构差异较大，应建立类别内分位数阈值和历史价格参照库，避免用同一固定阈值判断所有项目。

第三，建立供应商低价中标画像机制。对供应商中标次数、低价中标次数、平均节约率、跨省中标比例和服务类别广度进行持续更新，形成供应商风险画像。对高频低价中标且网络中心性较高的供应商，应强化履约质量和报价合理性复核。

第四，加强高风险采购方式和高风险地区监管。对于风险率较高的采购方式以及财政压力较高地区，应适当提高抽查比例，重点关注低价中标后的合同变更、追加采购和履约评价。

第五，建立中标后履约跟踪机制。异常低价项目的风险不止发生在中标阶段，还可能在履约阶段表现为服务质量下降、人员配置不足或后续变更增加。因此，应将模型预警结果与履约验收、投诉质疑和信用评价衔接，形成全过程监管闭环。对于连续低价中标且履约反馈较差的供应商，可适当提高后续项目的资格核验和履约抽查强度。

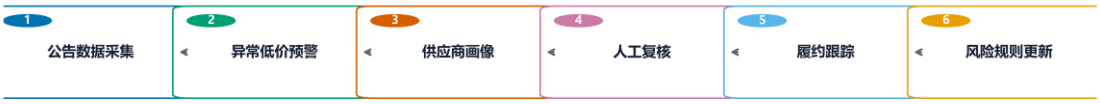


图 36 政府采购异常低价风险监管闭环图

（三）研究不足与展望

本文仍存在若干不足。第一，部分项目省份和城市字段由文本或城市映射推断，仍可能存在识别误差；第二，异常低价标签是风险标签而非执法认定，尚缺少履约质量、投诉处理和审计处罚等外部结果变量；第三，文本主题模型主要使用公告正文，尚未纳入招标文件全文和合同履约细节；第四，关系网络

以供应商—采购人为主，未来可进一步扩展到代理机构、评审专家和投诉处理等主体。后续研究可在更长时间序列和更完整履约数据基础上，对异常低价风险的动态演化、履约后果和治理效果开展评估，并进一步检验不同地区、不同采购类别下模型阈值的适用性。

参考文献

[1] 王宏, 门博, 雷娜. K 近邻算法在政府采购数据挖掘中的研究与应用[J]. 智能计算机与应用, 2019.

[2] 韩利利. 中标公告文本挖掘方法及在政府采购中的应用研究[D]. 硕士学位论文, 2018.

[3] 苏莹莹. 论政府采购中异常低价投标的法律规制[D]. 硕士学位论文, 2020.

[4] 张怀营. 对政府采购活动中异常低价投标行为的探讨——从财政部政府采购指导性案例 19 号切入[J]. 法学, 2024.

[5] 魏俊奎, 周顺凯, 金义. 基于大数据分析的电力供应商投标评估预测方案研究[J]. 微型电脑应用, 2019.

[6] 华玉雯. 大数据下围标串标现象识别研究[D]. 学位论文.

[7] 李玺, 崔永涛, 金坎明. 招投标全流程数据整合思路研究[C]. 智能电网信息化建设研讨会论文集, 2018.

[8] Jeong J, Lee H, Kim. An econometric identification of abnormally low bids in the procurement market: discriminant analysis[R]. Economic Research Institute Yonsei University, 2018.

[9] Conti P L, De Giovanni L, Naldi M. A rank-and-compare algorithm to detect abnormally low bids in procurement auctions[J]. Electronic Commerce Research and Applications.

[10] Hinojosa S, Muñoz F, Oviedo C. Abnormally low bids in PPPs: Analysis of evidence and a proposed statistical test[J].

[11] Rabuzin K, Modrušan N. Prediction of Public Procurement Corruption Indices using Machine Learning Methods[C].

[12] Lima W, Silva V, Silva J, Lira R, Paiva A. BidCorpus: A multifaceted learning dataset for public procurement[J]. Data in Brief, 2025.

[13] Fazekas M, Tóth I J, King L P. An objective corruption risk index using public procurement data[J]. European Journal on Criminal Policy and Research, 2016.

[14] Decarolis F, Giorgiantonio C. Corruption red flags in public procurement: new evidence from Italian calls for tenders[J]. EPJ Data Science, 2022.

[15] Katona E, Fazekas M. Hidden barriers to open competition: Using text mining to uncover corrupt restrictions to competition in public procurement[R]. 2024.

[16] Lyra M S, Pinheiro F L, Bação F. Public Procurement Fraud Detection: A Review Using Network Analysis[C]. 2022.

[17] Salton G, Buckley C. Term-weighting approaches in automatic text retrieval[J]. Information Processing & Management, 1988.

[18] Blei D M, Ng A Y, Jordan M I. Latent Dirichlet Allocation[J]. Journal of Machine Learning Research, 2003.

[19] Liu F T, Ting K M, Zhou Z H. Isolation Forest[C]. IEEE International Conference on Data Mining, 2008.

[20] Breunig M M, Kriegel H P, Ng R T, Sander J. LOF: Identifying density-based local outliers[C]. ACM SIGMOD, 2000.

[21] Schölkopf B, Platt J C, Shawe-Taylor J, Smola A J, Williamson R C. Estimating the support of a high-dimensional distribution[J]. Neural Computation, 2001.

[22] Breiman L. Random Forests[J]. Machine Learning, 2001.

[23] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]. KDD, 2016.

[24] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. NIPS, 2017.

[25] Pappas I O, Woodside A G. Fuzzy-set Qualitative Comparative Analysis (fsQCA): Guidelines for research practice in Information Systems and marketing[J]. International Journal of Information Management, 2021.